

UNIVERSIDAD EAFIT
Escuela de Ciencias Aplicadas e Ingeniería
Programa de Ingeniería Física

Sistema de clasificación de hologramas de glóbulos
rojos para la detección de anemia falciforme basado en
aprendizaje automático interpretable

Trabajo de grado

Autor: Santiago Ochoa Villegas
Tutor: Carlos Alejandro Trujillo

Medellín, Colombia
2025

Contenido

1. Introducción	10
1.1. Contexto clínico y desafíos actuales	10
1.2. Microscopía holográfica como oportunidad tecnológica	10
1.3. Aprendizaje automático interpretable	11
1.4. Enfoque del proyecto	11
1.5. Ciencia abierta y transferencia tecnológica	12
1.6. Contribuciones y estructura del documento	12
2. Planteamiento del problema	14
2.1. Contexto y brecha diagnosticada	14
2.2. Pregunta de investigación	14
2.3. Objetivos específicos	15
2.4. Alcance y delimitaciones	15
2.5. Limitaciones y riesgos	16
2.6. Hipótesis y productos esperados	16
3. Marco teórico	17
3.1. Microscopía holográfica sin lente	17
3.1.1. Propagación y modelado matemático	18
3.1.2. Fenómenos de muestreo y discretización	18
3.2. Fisiopatología de la anemia falciforme y retos diagnósticos	19
3.3. Representación de hologramas	20
3.4. Estado del arte en clasificación holográfica	21
3.5. Modelos de clasificación	22
3.5.1. Regresión logística	22
3.5.2. Máquinas de soporte vectorial	22
3.5.3. Métodos basados en árboles	23

3.5.4. Ensamble heterogéneo	23
3.6. Aprendizaje profundo y enfoques híbridos	23
3.7. Validación estadística	24
3.8. Detección de anomalías	24
3.9. Interpretabilidad y consideraciones éticas	25
3.10. Síntesis del marco teórico	26
4. Metodología	27
4.1. Descripción de los datos	27
4.2. Unificación y preprocesamiento	28
4.3. Extracción de características	29
4.4. Selección de características	29
4.5. Análisis exploratorio y control de calidad	30
4.6. Modelos y ensamble	30
4.7. Planteamiento matemático del clasificador	31
4.8. Validación y métricas	32
4.9. Plan experimental y modos de ejecución	33
4.10. Detección de anomalías	33
4.11. Automatización e interfaz	34
4.12. Infraestructura de ejecución y reproducibilidad	34
4.13. Gestión de riesgos y calidad	35
5. Desarrollo experimental y de ingeniería	36
5.1. Estructura del repositorio	36
5.2. Diseño del pipeline	37
5.3. Modos de operación	37
5.4. Automatización de reportes	38
5.5. Integración del detector de anomalías	38
5.6. Consideraciones de desempeño	39
5.7. Gestión de configuraciones	39
5.8. Retos enfrentados	39
5.9. Cronograma de iteraciones	40
5.10. Pruebas automatizadas y verificación continua	40
5.11. Estrategia de empaquetado y despliegue	41
5.12. Documentación y soporte	41
6. Resultados y análisis	42
6.1. Rendimiento del clasificador	42

6.2. Importancia de características	44
6.3. Análisis estadístico complementario	46
6.4. Validación fuera de dominio	46
6.5. Comparación con antecedentes	48
6.6. Sensibilidad a hiperparámetros	48
6.7. Discusión	49
7. Conclusiones y trabajo futuro	51

Lista de Figuras

6.1. Matriz de confusión producida en el modo profundo.	44
6.2. Curva ROC del ensamble entrenado en modo profundo.	44
6.3. Distribución de las características más discriminativas según Cohen's d	45
6.4. Comparativa de desempeño entre los clasificadores base y el ensamble final.	46
6.5. Distribución de distancias de Mahalanobis para muestras ex- ternas.	47
6.6. Mapa de calor de predicciones y distancias para organismos no sanguíneos.	48

Lista de Tablas

6.1. Comparativo de métricas globales por modo de ejecución. . . .	43
6.2. Resumen de validación cruzada y Leave-One-Out.	43
6.3. Resultados de la detección de anomalías en el conjunto externo.	47

Resumen

La anemia falciforme continúa siendo una condición hemoglobinopática de alto impacto social y clínico, especialmente en regiones donde el acceso a laboratorios especializados resulta limitado. Las metodologías diagnósticas estándar dependen de equipamiento costoso, procesos de tinción y personal altamente entrenado, lo que retrasa campañas de cribado oportunas. En respuesta a esta brecha, el presente trabajo de grado propone un sistema de clasificación automatizado que analiza hologramas generados mediante microscopía digital sin lentes. La hipótesis sostiene que, aun sin reconstruir el campo óptico, es posible discriminar entre glóbulos rojos sanos y células falciformes si se combinan descriptores de textura, forma y frecuencia con modelos de aprendizaje automático clásicos y un módulo de detección de anomalías interpretable.

El estudio parte de un conjunto de 304 hologramas rotulados (151 sanos y 153 enfermos) y de un repositorio de validación externa compuesto por hologramas de organismos ajenos a la sangre. La metodología abarca la unificación automatizada de bases heterogéneas, la extracción de 84 características físicas y estadísticas, la selección de atributos relevantes y la construcción de un ensamble de clasificadores compuesto por regresión logística, máquinas de soporte vectorial, bosques aleatorios y gradiente por potenciación. Se integró, además, un detector de anomalías basado en la distancia de Mahalanobis para identificar muestras fuera de dominio y complementar la interpretación de las decisiones del modelo principal.

El pipeline se implementó en una interfaz de línea de comandos reproducible que permite ejecutar análisis rápidos, completos o profundos. Las campañas experimentales alcanzaron una exactitud de prueba del 95,1 % en modo rápido y un área bajo la curva ROC de 0,995 en configuración profunda, con

validación cruzada estratificada y Leave-One-Out. Asimismo, la detección de anomalías etiquetó correctamente el 100 % de los hologramas no sanguíneos. Los resultados demuestran que la sinergia entre óptica computacional y aprendizaje automático interpretable habilita soluciones de diagnóstico portátiles, transparentes y escalables.

Palabras clave: anemia falciforme, microscopía holográfica sin lente, aprendizaje automático interpretable, detección de anomalías, análisis de patrones.

Abstract

Sickle cell disease remains a high-impact hemoglobinopathy, particularly in regions where specialized laboratories are scarce. Conventional diagnostics depend on costly instrumentation, chemical staining, and expert cytotechnologists, which hinders timely screening. This thesis introduces an automated system that classifies holograms captured with lensless digital holographic microscopy. The guiding hypothesis is that raw interference patterns contain enough discriminative cues to separate healthy erythrocytes from sickled cells when texture, morphology, and frequency descriptors are combined with classic interpretable machine-learning models and an anomaly detection layer.

The study is grounded on a curated dataset of 304 labeled holograms (151 healthy, 153 sickle cell) and an external repository of non-blood specimens. The methodology encompasses automatic dataset unification, extraction of 84 physics-inspired features, feature selection, and the construction of an ensemble that blends logistic regression, support vector machines, random forests, and gradient boosting classifiers. An anomaly detector based on the Mahalanobis distance complements the ensemble by flagging out-of-distribution samples and providing interpretable evidence for extreme cases.

The end-to-end pipeline is delivered as a reproducible command-line interface that supports quick, full, and deep analysis modes. Experimental campaigns reached a test accuracy of 95.1 % in quick mode and a ROC-AUC of 0.995 in deep mode, leveraging stratified cross-validation and Leave-One-Out schemes. The anomaly detector correctly identified 100 % of the non-blood holograms. These outcomes demonstrate that the synergy between computational optics and interpretable machine learning enables portable, transparent, and scalable diagnostic solutions.

Keywords: sickle cell disease, lensless digital holographic microscopy, inter-

pretable machine learning, anomaly detection, pattern analysis.

Capítulo 1

Introducción

1.1. Contexto clínico y desafíos actuales

La anemia falciforme es una hemoglobinopatía hereditaria que afecta la capacidad de transporte de oxígeno y causa episodios recurrentes de dolor, deterioro orgánico y una disminución significativa de la expectativa de vida. Se calcula que cada año nacen más de 300 000 niños con la enfermedad y que la prevalencia se mantiene elevada en regiones tropicales y subtropicales debido a la ventaja heterocigota frente a la malaria [1]. A pesar de los avances terapéuticos, el diagnóstico oportuno continúa siendo un reto, particularmente en contextos donde las infraestructuras de laboratorio y los suministros para cromatografía, electroforesis o pruebas moleculares son escasos [2, 3]. Las pruebas de punto de cuidado han mejorado la detección en algunos escenarios, pero su precisión y sensibilidad aún no alcanzan los estándares deseables para implementar programas de cribado universal. Persisten además brechas logísticas relacionadas con la conservación de reactivos, la capacitación de personal y la trazabilidad de resultados en regiones rurales.

1.2. Microscopía holográfica como oportunidad tecnológica

La microscopía digital holográfica sin lente (DLHM, por sus siglas en inglés) surge como una alternativa de bajo costo y alta portabilidad que emplea

fuentes de luz coherente y sensores comerciales para capturar patrones de interferencia con una sola toma [4, 5]. Estos sistemas prescinden de objetivos ópticos complejos, por lo que reducen drásticamente los costos y el tamaño del hardware, cualidades claves para iniciativas de telemedicina y para campañas de cribado en terreno. No obstante, buena parte de la literatura se centra en reconstruir el campo óptico para visualizar las células, proceso que implica transformadas de Fourier, conocimiento preciso de la geometría del montaje y un costo computacional elevado [6]. Explorar la clasificación directa de hologramas sin reconstrucción abre la posibilidad de desarrollar herramientas portátiles que entreguen diagnósticos rápidos, preserven la información física original y minimicen la intervención humana.

1.3. Aprendizaje automático interpretable

El auge del aprendizaje automático ha impulsado soluciones diagnósticas en hematología digital, desde redes convolucionales profundas hasta sistemas híbridos que combinan extracción manual de características [7, 8, 9]. Sin embargo, muchos modelos se comportan como “cajas negras” y requieren volúmenes de datos difíciles de conseguir en entornos hospitalarios con recursos limitados. Diversas revisiones subrayan la necesidad de metodologías validadas estadísticamente para muestras pequeñas y con mecanismos claros de explicación [10, 11, 12]. En este contexto, apostar por descriptores físicos interpretables y algoritmos clásicos con buen comportamiento en datasets moderados resulta una estrategia pragmática que prioriza la auditoría de resultados y la adopción clínica.

1.4. Enfoque del proyecto

El trabajo parte de un repositorio propio de hologramas de eritrocitos sanos y falciformes, así como de un conjunto adicional de organismos no sanguíneos usados para validar la detección de muestras fuera de dominio. A partir de estos datos se diseña un sistema modular que contempla la unificación automática del dataset, la normalización geométrica, la extracción de 84 características de textura, forma y frecuencia, la selección de atributos relevantes y la construcción de un ensamble de clasificadores. Se integra también un detector de anomalías basado en la distancia de Mahalanobis [13, 14] con el

fin de señalar patrones que se apartan de la distribución latente de células sanguíneas. El pipeline se encapsula en una interfaz de línea de comandos que automatiza la generación de reportes, la creación de modelos y la evaluación con datos externos.

1.5. Ciencia abierta y transferencia tecnológica

Además del beneficio clínico, la digitalización de hologramas abre la puerta a iniciativas de ciencia abierta. Trabajar con archivos ligeros y un pipeline automatizado facilita compartir modelos, datos sintéticos y protocolos con comunidades médicas internacionales, acelerando la validación cruzada y la generación de evidencia replicable [7]. Este proyecto se adhiere a ese espíritu al documentar el código en un repositorio público, publicar dependencias, describir requisitos de hardware y desarrollar guías reproducibles en español e inglés. También se contemplan aspectos de propiedad intelectual y licenciamiento conforme al reglamento de la Universidad EAFIT [15].

1.6. Contribuciones y estructura del documento

Este manuscrito aporta cuatro contribuciones principales: (i) un marco teórico que enlaza los fundamentos ópticos de DLHM con las necesidades clínicas del diagnóstico de anemia falciforme; (ii) un pipeline reproducible que automatiza la extracción de características, la validación cruzada y la generación de reportes; (iii) la demostración experimental de que un ensamble de clasificadores clásicos puede alcanzar desempeños comparables a aproximaciones profundas con menor demanda computacional; y (iv) la integración de un detector de anomalías interpretable que alerta sobre hologramas fuera de dominio.

La estructura del documento refleja esta hoja de ruta. El Capítulo `refchap:problema` formaliza la pregunta de investigación, los objetivos y el alcance. El Capítulo `refchap:marco` desarrolla el marco teórico con énfasis en la interacción entre óptica y aprendizaje automático. El Capítulo `refchap:metodologia` describe la metodología seguida para construir y validar

el sistema. El Capítulo

refchap:desarrollo detalla la implementación, las decisiones de ingeniería y los desafíos encontrados. El Capítulo

refchap:resultados recoge los hallazgos cuantitativos y cualitativos. Finalmente, el Capítulo

refchap:conclusiones presenta las conclusiones generales y las líneas de trabajo futuro, las cuales delinean la agenda para desplegar soluciones clínicas basadas en holografía digital.

Capítulo 2

Planteamiento del problema

2.1. Contexto y brecha diagnosticada

El diagnóstico diferencial de la anemia falciforme en ambientes de bajos recursos enfrenta un dilema recurrente: por un lado, los métodos confirmatorios como la cromatografía líquida de alta resolución o la electroforesis ofrecen elevada sensibilidad; por otro, su costo y dependencia de laboratorios especializados dificultan la detección temprana en zonas rurales o en campañas masivas [2, 3]. La microscopía digital holográfica sin lente promete reducir las barreras logísticas, pero almacenar y procesar los hologramas mediante cadenas de reconstrucción complejas compromete la inmediatez diagnóstica [4, 5]. En consecuencia, la comunidad científica se pregunta si es factible automatizar la clasificación de eritrocitos sanos y falciformes directamente sobre los patrones interferométricos, conservando su información física y evitando etapas costosas de reconstrucción [6, 7].

2.2. Pregunta de investigación

A partir de esta brecha se formula la siguiente pregunta central:

¿Es posible desarrollar un sistema de aprendizaje automático interpretable que clasifique hologramas de eritrocitos sanos y falciformes sin reconstrucción digital, garantizando métricas clínicas robustas y detección confiable de muestras fuera de dominio?

La pregunta sintetiza tres preocupaciones: exactitud diagnóstica, interpretabilidad y capacidad de alerta frente a entradas ajenas al dominio de entrenamiento.

2.3. Objetivos específicos

Para abordar la pregunta se definieron los siguientes objetivos:

- Diseñar un pipeline reproducible que unifique distintos repositorios de hologramas, normalice las imágenes y extraiga características físicas relevantes.
- Evaluar descriptores de textura, morfología y frecuencia con modelos clásicos de aprendizaje supervisado, e integrar un esquema de ensamble que mejore la generalización.
- Implementar un mecanismo de validación exhaustiva en escenarios de datos limitados, incluyendo validación cruzada estratificada y Leave-One-Out.
- Incorporar un detector de anomalías que identifique hologramas ajenos al dominio de entrenamiento y provea información interpretativa sobre la desviación de cada muestra.
- Comparar el desempeño del sistema frente a la literatura vigente y analizar su potencial de despliegue en contextos clínicos de bajo costo.

2.4. Alcance y delimitaciones

El proyecto se circunscribe a la clasificación binaria Healthy vs. SCD empleando un dataset capturado con un mismo arreglo holográfico. No se aborda el diseño óptico detallado del hardware ni la reconstrucción numérica de los hologramas. Tampoco se incluyen tareas de segmentación celular individual ni diagnósticos diferenciales con otras patologías hemoglobinopáticas. El sistema se ejecuta en un entorno Python y asume acceso a recursos de cómputo moderados (CPU multinúcleo) y a las dependencias consignadas en el repositorio. El entrenamiento se realiza con 304 hologramas rotulados y la validación externa con 30 hologramas de organismos no sanguíneos, los cuales sirven como proxy de interferencias ambientales.

2.5. Limitaciones y riesgos

Entre las principales limitaciones se destacan el tamaño relativamente reducido del dataset y la falta de parámetros ópticos exactos del montaje, lo que restringe la posibilidad de modelar analíticamente la respuesta del sistema. Asimismo, la generalización hacia muestras capturadas con otros sensores o bajo distintas condiciones de iluminación requiere experimentos adicionales. Para mitigar estos riesgos se adoptaron estrategias de validación estrictas, se documentaron todas las decisiones de ingeniería y se habilitaron reportes automáticos que permiten auditar cada ejecución. También se reconoce la necesidad de realizar estudios clínicos controlados antes de cualquier despliegue asistencial.

2.6. Hipótesis y productos esperados

La hipótesis a contrastar establece que un conjunto de descriptores interpretables combinado con un ensamble de clasificadores lineales y basados en árboles, complementado por un detector de anomalías de Mahalanobis, alcanza métricas superiores al 90 % de exactitud y AUC en evaluación cruzada, además de una sensibilidad elevada ante datos fuera de dominio. La verificación de esta hipótesis implicó desarrollar una infraestructura de software, ejecutar experimentos en tres modos operativos (rápido, completo y profundo) y analizar cuantitativamente los resultados.

El proyecto entrega como productos intermedios un modelo entrenado serializado, reportes automatizados que resumen las métricas clave y una guía operativa para usuarios finales. Estos elementos constituyen la base para validaciones clínicas futuras y conforman el paquete mínimo requerido por las políticas de propiedad intelectual de la universidad [15].

Capítulo 3

Marco teórico

Este capítulo articula los fundamentos físicos de la microscopía digital holográfica sin lente con los conceptos de aprendizaje automático que sustentan el sistema propuesto. Se enfatizan los modelos matemáticos que describen la formación del holograma, los descriptores utilizados para representar la información óptica y los algoritmos de clasificación y detección de anomalías seleccionados.

3.1. Microscopía holográfica sin lente

La microscopía digital holográfica sin lente (DLHM) se apoya en la interferencia entre una onda de referencia casi plana y una onda objeto que ha interactuado con la muestra biológica. Al iluminar con una fuente coherente, típicamente un LED colimado o un diodo láser, el objeto modula en fase y amplitud el frente de onda incidente. El sensor registra la intensidad

$$I(x, y) = |U_{\text{ref}}(x, y) + U_{\text{obj}}(x, y)|^2 = |U_{\text{ref}}|^2 + |U_{\text{obj}}|^2 + 2\Re\{U_{\text{ref}}U_{\text{obj}}^*\}, \quad (3.1)$$

donde U_{ref} es la onda de referencia y U_{obj} la onda difractada por el objeto [4]. Al carecer de lentes, la distancia entre la muestra y el sensor controla el régimen de difracción. En configuraciones típicas de DLHM se opera en el régimen de Fresnel, en el cual la propagación puede aproximarse mediante

$$U_{\text{obj}}(x, y, z) = \frac{e^{jkz}}{j\lambda z} \iint U(x', y', 0) \exp \left\{ \frac{jk}{2z} [(x - x')^2 + (y - y')^2] \right\} dx' dy', \quad (3.2)$$

con λ la longitud de onda y $k = 2\pi/\lambda$ [16]. Esta expresión evidencia que, aun sin reconstrucción numérica explícita, el holograma codifica diferencias espaciales ligadas a la morfología celular. Diversos estudios han demostrado que estructuras hemáticas con anisotropías pronunciadas, como las células falciformes, generan patrones de difracción diferenciables [5].

3.1.1. Propagación y modelado matemático

El formalismo de Rayleigh–Sommerfeld describe la propagación de una onda escalar en el espacio libre. Bajo la aproximación de Fresnel se adopta un filtro cuadrático que facilita su implementación digital, permitiendo expresar la propagación como una multiplicación en el dominio de Fourier. Si $\mathcal{F}\{\cdot\}$ denota la transformada bidimensional, la reconstrucción numérica clásica se formula como

$$U(x, y, z) = \mathcal{F}^{-1} \left\{ \mathcal{F}\{U(x, y, 0)\} \exp \left[-j\pi\lambda z (f_x^2 + f_y^2) \right] \right\}, \quad (3.3)$$

siendo (f_x, f_y) las frecuencias espaciales [16]. Esta convolución refleja que el holograma contiene las componentes de fase y amplitud necesarias para recuperar el frente de onda original. Trabajar directamente con el patrón interferométrico evita el costo computacional de la reconstrucción y elimina la necesidad de estimar con precisión la distancia z .

3.1.2. Fenómenos de muestreo y discretización

La digitalización impone restricciones de Nyquist sobre la frecuencia espacial máxima capturable. Para un sensor con paso Δ , la frecuencia máxima es $1/(2\Delta)$, por lo que la distancia muestra–sensor debe seleccionarse para evitar aliasing y asegurar que los órdenes de difracción relevantes se mantengan dentro de la ventana de observación [16]. Asimismo, la iluminación debe presentar suficiente coherencia temporal y espacial para garantizar contrastes elevados en el patrón. En DLHM portátiles se emplean LEDs con filtros estrechos o diodos láser de bajo costo, asumiendo que la coherencia temporal domina sobre la espacial. La ausencia de lentes introduce el fenómeno de la imagen gemela, un término complejo conjugado que puede interferir con la reconstrucción cuando no se filtra correctamente. En el enfoque propuesto esto deja de ser un problema, porque el clasificador trabaja directamente con el patrón de intensidades registrado, aprovechando la totalidad de la

información interferométrica sin cancelar componentes complejas. Además, la distancia corta entre muestra y sensor otorga un campo de visión amplio que permite capturar múltiples eritrocitos por cuadro, potenciando la eficiencia de los programas de cribado.

En comparación con la microscopía con lentes, DLHM ofrece un campo de visión ampliado, ausencia de componentes ópticos costosos y un volumen reducido del hardware [4]. Sin embargo, al capturar la intensidad en lugar de la fase, la información registrada se presenta como un patrón de moteado que debe ser interpretado mediante técnicas digitales. Tradicionalmente se recurría a algoritmos de reconstrucción numérica basados en transformadas de Fourier para recuperar el campo complejo, lo que exige una etapa adicional de filtrado y requiere conocer parámetros exactos de la geometría óptica [6]. Esta tesis explora una ruta alternativa: trabajar directamente sobre el holograma registrado, lo que conlleva analizar su textura, simetría y estadísticos de intensidad.

3.2. Fisiopatología de la anemia falciforme y retos diagnósticos

La anemia falciforme se origina por una mutación puntual en el gen de la cadena β de la hemoglobina, que induce la polimerización de la hemoglobina S bajo condiciones de hipoxia. La adopción de una forma rígida y alargada compromete la deformabilidad de los eritrocitos, obstruye capilares y desencadena crisis vaso-oclusivas [1]. Los métodos diagnósticos convencionales comprenden electroforesis, cromatografía líquida de alta resolución y ensayos moleculares, técnicas que demandan infraestructura especializada y personal entrenado [2, 3]. El análisis microscópico directo de frotis sanguíneos continúa siendo relevante, pero depende de la experiencia del citotecnólogo y se encuentra expuesto a variabilidad interobservador.

DLHM ofrece una alternativa portable para capturar patrones ópticos sin elementos voluminosos. No obstante, la identificación automática de células falciformes en hologramas enfrenta desafíos adicionales: (i) la coexistencia de eritrocitos sanos y enfermos en un mismo campo; (ii) artefactos ópticos producidos por polvo o microorganismos; y (iii) variaciones en la distancia muestra-sensor durante la captura. Por ello resulta indispensable disponer de

estrategias computacionales robustas que sigan principios estadísticos sólidos y sean interpretables para el personal sanitario.

3.3. Representación de hologramas

Los hologramas capturados poseen propiedades de textura cuasi-periódica y simetría radial que pueden cuantificarse con descriptores estadísticos. En este trabajo se utilizan 84 características agrupadas en cuatro familias principales:

1. **Textura de nivel de gris.** La matriz de coocurrencia de niveles de gris (GLCM) cuantifica asociaciones entre píxeles separados por distancias y ángulos definidos [17]. Sus derivados—contraste, correlación, homogeneidad y energía—captan regularidades en el patrón interferométrico. El Local Binary Pattern (LBP) codifica transiciones de intensidad alrededor de cada píxel y es sensible a micropatrones circulares asociados con irregularidades de la célula [18].
2. **Dominios de frecuencia.** La transformada rápida de Fourier (FFT) y los filtros de Gabor permiten identificar frecuencias dominantes y orientaciones táctiles. Los hologramas de células falciformes tienden a mostrar energía desplazada hacia altas frecuencias debido a bordes pronunciados [7].
3. **Características morfológicas.** Medidas como área, perímetro, circularidad, convexidad y solidez se calculan sobre binarizaciones suaves del holograma. Aunque no se segmenta la célula de forma estricta, estas métricas reflejan la distribución espacial de intensidades y correlacionan con la forma general de la célula [19].
4. **Momentos invariantes.** Los momentos de Hu capturan relaciones globales que permanecen invariantes ante rotaciones y escalados, útiles para comparar hologramas con orientaciones distintas [20].

Estos descriptores han sido empleados en aplicaciones biomédicas con buenos resultados cuando la cantidad de datos no permite entrenar redes profundas [21]. La literatura reporta que combinaciones híbridas de GLCM y LBP elevan la sensibilidad en tareas de diagnóstico hematológico porque capturan simultáneamente periodicidad global y microtexturas locales [18]. Complementar estas medidas con momentos y morfología permite interpretar la señal holográfica en múltiples escalas. Su principal ventaja es la interpretabilidad: cada métrica está asociada con una propiedad física o geométrica

del holograma.

Para mejorar la estabilidad numérica se normalizan los vectores de características mediante estadísticos robustos y se calcula el estadístico d de Cohen que cuantifica la separación entre clases. Esta medida de efecto, junto con los pesos asignados por el ensamble, constituye la base de los argumentos interpretables reportados en los capítulos posteriores. Adicionalmente, se monitorea la correlación entre características para detectar redundancias; cuando se identifican pares altamente correlacionados se priorizan aquellos con mayor respaldo teórico (por ejemplo, solidez frente a convexidad) y se documentan las decisiones de descarte para mantener trazabilidad.

3.4. Estado del arte en clasificación holográfica

Investigaciones recientes han explorado múltiples estrategias para explotar hologramas en tareas biomédicas. Amann *et al.* presentaron una plataforma abierta y de bajo costo capaz de capturar hologramas con componentes impresos en 3D, demostrando la viabilidad de despliegues masivos [4]. Buitrago-Duque *et al.* diseñaron un prototipo compacto para análisis de frotis sanguíneos que, si bien depende de reconstrucción numérica, abrió la puerta a aplicaciones clínicas portátiles [5]. En el ámbito del aprendizaje profundo, O'Connor *et al.* emplearon redes convolucionales para analizar dinámicas celulares en holografía digital con resultados prometedores [7], mientras que Darrin *et al.* combinaron arquitecturas recurrentes y convolucionales para estudiar movimientos de eritrocitos [22].

No obstante, la mayoría de estos enfoques se apoyan en grandes volúmenes de datos, requieren GPUs para entrenamiento y presentan dificultades de interpretabilidad. Adicionalmente, pocos trabajos reportan protocolos de validación robustos para datasets limitados, un problema conocido que puede inflar las métricas reportadas [10, 11]. La propuesta de esta tesis se diferencia al privilegiar descriptores físicos explicables, integrar un ensamble heterogéneo y complementar el clasificador con un detector de anomalías, todo ello documentado bajo un pipeline reproducible.

3.5. Modelos de clasificación

Partiendo de la matriz de características, la tarea de clasificación se aborda con modelos supervisados clásicos que ofrecen explicabilidad y rendimiento competitivo en datasets pequeños.

3.5.1. Regresión logística

La regresión logística modela la probabilidad de la clase positiva $y = 1$ como

$$P(y = 1 \mid \mathbf{x}) = \sigma(\mathbf{w}^\top \mathbf{x} + b), \quad (3.4)$$

donde σ es la función sigmoide. Sus coeficientes permiten interpretar la contribución marginal de cada característica, y la regularización L_2 mitiga el sobreajuste [23]. El entrenamiento consiste en maximizar la log-verosimilitud penalizada

$$\mathcal{L}(\mathbf{w}, b) = \sum_{i=1}^n [y_i \log \hat{p}_i + (1 - y_i) \log(1 - \hat{p}_i)] - \frac{\lambda}{2} \|\mathbf{w}\|_2^2, \quad (3.5)$$

donde $\hat{p}_i$ representa la probabilidad estimada para la muestra i y λ controla la magnitud de la penalización. Este término regula la complejidad del modelo y evita coeficientes desmesurados en presencia de datasets pequeños. Además, los signos de $\mathbf{w}$ permiten conocer si una característica favorece la clasificación como SCD (coeficiente positivo) o como Healthy (coeficiente negativo), propiedad que facilita contrastar los resultados con la fenomenología óptica descrita en secciones previas.

3.5.2. Máquinas de soporte vectorial

Las máquinas de soporte vectorial (SVM) con kernel radial buscan maximizar el margen entre clases en un espacio de características implícito. La decisión se expresa mediante

$$f(\mathbf{x}) = \text{sign} \left(\sum_{i=1}^N \alpha_i y_i K(\mathbf{x}, \mathbf{x}_i) + b \right), \quad (3.6)$$

donde K es un kernel gaussiano y los coeficientes α_i se obtienen resolviendo un problema cuadrático [20]. Las SVM se adaptan bien a datasets de alta

dimensión y tamaño moderado, proporcionando fronteras no lineales. Para evitar sobreajuste se utiliza validación cruzada durante la búsqueda de hiperparámetros y se normalizan las características, lo cual garantiza que los parámetros C y γ mantengan magnitudes razonables.

3.5.3. Métodos basados en árboles

Los bosques aleatorios construyen múltiples árboles de decisión sobre subconjuntos aleatorios de características y observaciones, y combinan sus predicciones mediante votación [24]. Esta técnica es especialmente útil para detectar interacciones entre características de distinta naturaleza, como texturas y momentos, y para cuantificar la importancia global de cada descriptor. Capturan interacciones no lineales y ofrecen medidas de importancia de características. El gradiente boosting, por su parte, entrena secuencialmente árboles débiles que corrigen los errores residuales del ensamble acumulado [25]. Ambas técnicas son robustas a escalas heterogéneas y toleran ruido moderado, atributos valiosos en hologramas capturados en condiciones reales.

3.5.4. Ensamble heterogéneo

El sistema integra los cuatro modelos anteriores mediante un ensamble de votación blanda. Cada clasificador aporta una probabilidad y el resultado final se obtiene al promediar ponderadamente estas salidas. Esta estrategia busca balancear sesgos: la regresión logística provee interpretabilidad lineal, la SVM aporta un margen amplio, los bosques aleatorios cubren interacciones complejas y el gradiente boosting ofrece refinamiento en regiones difíciles. La literatura reporta que los ensambles heterogéneos mejoran la generalización cuando los clasificadores son complementarios [20, 12]. En el contexto biomédico, la votación blanda reduce la probabilidad de cometer errores sistemáticos y facilita la calibración de probabilidades, un aspecto clave cuando las decisiones clínicas dependen de umbrales explícitos.

3.6. Aprendizaje profundo y enfoques híbridos

La bibliografía reciente reporta avances importantes en el uso de redes neuronales convolucionales para clasificar células sanguíneas y reconstruir hologramas [7, 22, 26]. Estos modelos ofrecen alta capacidad de representación, pero

demandan grandes cantidades de datos etiquetados y hardware especializado. Además, su interpretabilidad resulta limitada si no se emplean técnicas adicionales como mapas de saliencia o Grad-CAM. En entornos de baja disponibilidad de datos, aplicar redes profundas sin regularización puede conducir a sobreajustes severos y a decisiones difíciles de auditar.

En consecuencia, esta tesis adopta un enfoque híbrido que prioriza descriptores físicos y modelos explicables, pero deja abierta la posibilidad de integrar redes neuronales ligeras como extractores de características en futuras etapas. La combinación de ambos mundos permitiría explotar la representación distribuida de las CNN y, al mismo tiempo, conservar mecanismos interpretables como los coeficientes logísticos y las contribuciones de Mahalanobis. Esta perspectiva coincide con tendencias emergentes de aprendizaje automático explicable en medicina [12].

3.7. Validación estadística

El tamaño limitado del dataset exige protocolos de validación rigurosos. Se emplea validación cruzada estratificada de k pliegues con $k = 5$, que preserva la proporción de clases en cada partición [10]. Para estimar la estabilidad en muestras extremas, se ejecuta también validación Leave-One-Out (LOOCV), en la cual cada holograma actúa una vez como conjunto de prueba. Las métricas reportadas incluyen exactitud, sensibilidad, especificidad, precisión, área bajo la curva ROC y área bajo la curva de precisión-recall. Este repertorio sigue recomendaciones establecidas para estudios biomédicos con datos limitados [11].

3.8. Detección de anomalías

Tras entrenar el clasificador, se ajusta un detector de anomalías que opera sobre las mismas características. La distancia de Mahalanobis cuantifica el alejamiento de una muestra respecto a la distribución gaussiana multivariada estimada para las clases normales [13]. Su definición es

$$D_M(\mathbf{x}) = \sqrt{(\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu})}, \quad (3.7)$$

donde $\boldsymbol{\mu}$ es el vector promedio y $\boldsymbol{\Sigma}$ la matriz de covarianza. Asumiendo normalidad aproximada, D_M^2 sigue una distribución χ^2 con p grados de libertad,

lo que permite fijar umbrales percentilares [14]. En este proyecto se adopta el percentil 95, equivalente a tolerar un 5 % de falsos positivos. Además, se calculan contribuciones individuales de características evaluando el producto entre la desviación respecto a la media y la diagonal de Σ^{-1} , lo que ofrece evidencia interpretativa para cada detección.

El detector se aplica sobre hologramas externos de organismos como diatomeas, esporas fúngicas y estructuras vegetales. Estas categorías comparten la escala espacial de los eritrocitos, por lo que constituyen un reto realista para evaluar la sensibilidad del sistema ante interferencias ambientales. Estas muestras actúan como proxy de ruido procedente del entorno de captura y permiten cuantificar la capacidad del sistema para alertar cuando recibe entradas ajenas a su dominio de entrenamiento, requisito clave antes de desplegarse en contextos clínicos reales.

3.9. Interpretabilidad y consideraciones éticas

La integración de algoritmos interpretables es fundamental en aplicaciones médicas. Diversas revisiones señalan que la transparencia en los sistemas de apoyo diagnóstico incrementa la confianza del personal clínico y facilita la auditoría regulatoria [12]. En el presente trabajo, la interpretabilidad se garantiza en tres niveles: (i) los descriptores físicos mantienen una relación directa con propiedades ópticas o geométricas del holograma; (ii) los modelos lineales, como la regresión logística, ofrecen coeficientes interpretables que cuantifican la influencia marginal de cada característica; y (iii) el detector de anomalías proporciona contribuciones por característica que contextualizan los casos fuera de dominio. Esta combinación permite argumentar cada decisión y documentar posibles sesgos. Asimismo, se respetan lineamientos de protección de datos al trabajar exclusivamente con identificadores anónimos y almacenar los hologramas en servidores controlados por la institución.

La ética del despliegue también exige considerar la comunicación de resultados a pacientes y la supervisión médica. El sistema está concebido como herramienta de apoyo, no como sustituto del juicio clínico. Por ello, la interfaz recomienda explícitamente que cada reporte sea revisado por un profesional de la salud antes de emitir un diagnóstico definitivo.

3.10. Síntesis del marco teórico

Los elementos descritos en este capítulo convergen en un enfoque integral: la física del holograma fundamenta la selección de descriptores; la fisiopatología de la anemia falciforme orienta la interpretación biomédica; y los algoritmos de aprendizaje automático aportan el andamiaje estadístico para construir un sistema reproducible y confiable. La incorporación de un detector de anomalías responde a la necesidad de operar en contextos reales donde pueden aparecer contaminantes, mientras que las consideraciones éticas subrayan el papel complementario de la herramienta frente al criterio clínico. Este marco servirá como referencia para justificar las decisiones metodológicas y de diseño presentadas en los capítulos siguientes.

Capítulo 4

Metodología

Esta sección describe la estrategia integral seguida para desarrollar el sistema de clasificación holográfica, desde la curaduría del dataset hasta la validación estadística y la generación de reportes automatizados. La metodología se diseñó con el propósito de ser reproducible, interpretable y extensible.

4.1. Descripción de los datos

El repositorio primario está compuesto por dos colecciones heterogéneas capturadas con un mismo arreglo DLHM: *dataset_1* y *dataset_2*. Cada captura siguió protocolos de iluminación idénticos para preservar la comparabilidad y se almacenó junto a metadatos de fecha y operador. La primera contiene hologramas de eritrocitos sanos y falciformes provenientes de un banco de sangre local, mientras que la segunda reúne muestras adquiridas en condiciones controladas de laboratorio. Cada archivo está almacenado en formato PNG con resolución máxima de 4640×3506 píxeles y profundidad de color de 8 bits. En total se disponen 304 hologramas rotulados, distribuidos en 151 sanos y 153 falciformes. El etiquetado proviene de expertos hematólogos y se mantuvo la información de procedencia para permitir particiones estratificadas por sujeto cuando se requiera extender el estudio.

Adicionalmente se cuenta con un conjunto externo *holograms* que incluye tres categorías de organismos ajenos a la sangre (esporas de *Aspergillus*, diatomeas y partículas de la familia *Poaceae*). Este repositorio se emplea

exclusivamente para evaluar la detección de anomalías y simular la presencia de contaminantes o artefactos en la cadena de captura. Antes de cada corrida se verifica la integridad de los archivos mediante sumas de verificación y se documentan las versiones de cada lote de datos.

Para favorecer futuras ampliaciones, el repositorio se estructura con metadatos normalizados (origen, fecha, temperatura de captura) y se implementa control de acceso para preservar la anonimización de los donantes. Esta información facilita replicar experimentos, agregar nuevas cohortes e identificar sesgos potenciales asociados a procedencia o condiciones de medición.

4.2. Unificación y preprocesamiento

Para estandarizar la información, se implementó un módulo de unificación que crea un dataset consolidado bajo la estructura `data/unified`. El proceso contempla los siguientes pasos:

1. **Normalización geométrica.** Las imágenes de *dataset_1* presentan variaciones de tamaño y desplazamiento del objeto. Se extrae un parche central del holograma y se redimensiona a 512×512 píxeles utilizando interpolación bilineal. Para *dataset_2*, cuyos hologramas ya se encuentran centrados, solo se ajusta el tamaño si difiere del requerido.
2. **Codificación de clases.** Se homogeniza la nomenclatura de clases a *Healthy* y *SCD*, independientemente del nombre original de cada carpeta.
3. **Control de calidad.** Se descartan archivos corruptos o vacíos y se registra un log de procesamiento con estadísticas por clase.

El resultado es un directorio unificado listo para la extracción de características. Este procedimiento se ejecuta automáticamente cuando el usuario inicia el análisis desde la interfaz de línea de comandos.

Además, el módulo registra tiempos de ejecución, estadísticas de descarte y hashes de los archivos resultantes, lo que permite auditar el proceso y detectar desviaciones cuando se incorporan nuevas fuentes de datos. Esta bitácora de unificación ha sido útil para calibrar el comportamiento del montaje holográfico y documentar incidencias en campo.

4.3. Extracción de características

Sobre cada holograma normalizado se calculan 84 descriptores. Las etapas principales son:

- **Filtrado y normalización.** Se aplican filtros de mediana y ecualización adaptativa de histograma (CLAHE) para mitigar ruido de fondo y realzar contrastes locales [19].
- **Características de textura.** Se calcula la matriz GLCM con distancia de cinco píxeles y ángulo cero. De esta matriz se derivan estadísticos como contraste, correlación, homogeneidad y energía [17]. Además, se genera un histograma LBP con 24 puntos y radio de tres píxeles, del cual se extraen los primeros diez coeficientes.
- **Dominio frecuencial.** Se obtiene el espectro de magnitud mediante FFT y se agrupa la energía en anillos concéntricos (tres bandas). También se evalúan filtros de Gabor en múltiples orientaciones para captar anisotropías [7].
- **Momentos y morfología.** Se calculan los siete momentos invariantes de Hu, la extensión, la solidez, la relación de ejes, el perímetro normalizado y la relación área-convexidad.

Cada conjunto de características se almacena en archivos de cache individuales para acelerar ejecuciones posteriores. Además, se generan histogramas de control que permiten inspeccionar la distribución de cada descriptor y detectar valores atípicos potenciales antes del entrenamiento. Las métricas intermedias se registran en un archivo de trazas que permite auditar el comportamiento del extractor.

El extractor está modularizado de forma que nuevas familias de descriptores puedan añadirse con mínima intervención; el tiempo promedio por holograma ronda los 0,45 s en CPU, por lo que la reutilización del cache reduce significativamente los ciclos de experimentación y evita recalcular transformadas costosas.

4.4. Selección de características

Aunque el vector de 84 características es manejable, se emplea un proceso de selección para priorizar atributos con mayor poder discriminante. Se adopta *SelectKBest* con estadístico ANOVA F para evaluar la diferencia de medias

entre clases [27]. Dependiendo del modo de operación, el pipeline conserva las mejores 20 características (modo rápido) o hasta 50 (modo profundo). La selección se actualiza en cada ejecución para reflejar posibles variaciones en el dataset y permite interpretar cuáles descriptores físicos influyen más en la predicción.

Adicionalmente se analizan los conjuntos de características seleccionados en corridas consecutivas para estimar su estabilidad; aquellos atributos que aparecen de forma recurrente se documentan en el reporte final como candidatos robustos para estudios futuros o para su traducción a indicadores ópticos medibles.

4.5. Análisis exploratorio y control de calidad

Previo al entrenamiento se realiza un análisis exploratorio que incluye histogramas por característica, gráficas de dispersión proyectadas mediante análisis de componentes principales y evaluación de outliers mediante puntuaciones z robustas. Los resultados orientan ajustes en los parámetros de normalización y permiten detectar problemas de adquisición (por ejemplo, hologramas saturados o con iluminación desigual). El pipeline registra automáticamente estas inspecciones en un cuaderno electrónico, lo que facilita comparar ejecuciones y documentar decisiones correctivas.

Cuando el análisis exploratorio identifica desviaciones marcadas se detona un flujo de revisión manual y, de ser necesario, se excluyen temporalmente las imágenes afectadas hasta resolver la causa raíz. Este control temprano evita que artefactos triviales sesguen el entrenamiento o inflen las métricas de validación.

4.6. Modelos y ensamble

La etapa de entrenamiento comienza dividiendo el dataset en conjuntos de entrenamiento y prueba con proporción 80/20 y estratificación por clase. Sobre el conjunto de entrenamiento se entrenan cuatro modelos base: regresión logística regularizada, SVM con kernel radial, bosque aleatorio de 200 árboles y clasificador de gradiente boosting con 300 iteraciones. Los hiperparámetros se optimizan mediante búsqueda aleatoria y validación cruzada interna. Pos-

teriormente, las probabilidades resultantes se combinan a través de votación blanda con pesos ajustados según la métrica ROC-AUC obtenida durante la validación.

El modo profundo activa la optimización exhaustiva de hiperparámetros mediante *GridSearchCV*, incrementa el número máximo de características y extiende el tiempo de búsqueda. Los espacios de búsqueda consideran rangos amplios para parámetros como la regularización de la regresión logística, el parámetro C y la anchura del kernel en la SVM, el número de estimadores en los bosques aleatorios y la tasa de aprendizaje del gradiente boosting. En contraste, el modo rápido deshabilita la optimización avanzada para reducir costos computacionales y acelerar el uso durante etapas de prueba.

Finalmente, el entrenamiento se automatiza con un control de semillas y una verificación de convergencia que detiene procesos divergentes; los logs almacenan las configuraciones óptimas de cada modelo para facilitar su replicación o su despliegue en producción.

4.7. Planteamiento matemático del clasificador

Sea $D = \{(\mathbf{x}_i, y_i)\}_{i=1}^n$ el conjunto de entrenamiento, donde $\mathbf{x}_i \in \mathbb{R}^p$ representa el vector de características extraído del holograma y $y_i \in \{0, 1\}$ denota la etiqueta (0 para Healthy, 1 para SCD). Cada clasificador base produce una probabilidad $p_m(y = 1 \mid \mathbf{x})$. El ensamble combina estas salidas mediante votación blanda ponderada:

$$\hat{p}_{\text{ens}}(y = 1 \mid \mathbf{x}) = \frac{\sum_{m=1}^M w_m p_m(y = 1 \mid \mathbf{x})}{\sum_{m=1}^M w_m}, \quad (4.1)$$

donde w_m es el peso asignado al clasificador m proporcional a su AUC durante la validación cruzada y $M = 4$ en este proyecto. La predicción final se obtiene evaluando $\hat{p}_{\text{ens}}$ contra un umbral τ (por defecto, $\tau = 0,5$). La regresión logística calcula $p_1(y = 1 \mid \mathbf{x})$ como $\sigma(\mathbf{w}^\top \mathbf{x} + b)$, con la función sigmoide $\sigma(z) = 1/(1 + e^{-z})$. Sus parámetros $(\mathbf{w}, b)$ se optimizan maximizando la log-verosimilitud penalizada descrita en el Capítulo 3. La máquina de soporte vectorial genera un valor de decisión $f(\mathbf{x})$ que se transforma en probabilidad mediante calibración logística (sigmoid fitting) [20]. Para los bosques aleatorios, $p_3(y = 1 \mid \mathbf{x})$ corresponde al promedio de los votos positivos emitidos por cada árbol del conjunto. En el gradiente boosting, la

probabilidad se obtiene aplicando la función logística al puntaje agregado $F(\mathbf{x}) = \sum_{t=1}^T \gamma_t h_t(\mathbf{x})$, donde cada h_t es un árbol débil ajustado sobre los residuos de la iteración anterior [25]. Estas definiciones aseguran que las salidas de todos los clasificadores sean compatibles para la votación blanda. La matriz de confusión y las métricas derivadas se calculan con las etiquetas finales $\hat{y} = \mathbb{I}[\hat{p}_{\text{ens}} \geq \tau]$. Asimismo, las probabilidades se almacenan para cada muestra a fin de calcular medidas de incertidumbre, como la desviación estándar entre clasificadores base y las curvas ROC. Este planteamiento matemático facilita la auditoría del sistema y la comparación con modelos alternativos; en particular, permite cuantificar la contribución de cada modelo al desempeño global y diagnosticar desacuerdos internos.

Esta formalización también deja abierta la posibilidad de integrar funciones de pérdida ponderadas o criterios de decisión adaptativos, elementos que se explorarán cuando se incorporen nuevas clases diagnósticas o se traslade el sistema a entornos clínicos con requisitos regulatorios específicos.

4.8. Validación y métricas

El rendimiento del sistema se estima con diversos indicadores. Durante la fase de entrenamiento se calcula la exactitud en el conjunto de prueba separado (20 %). Para evaluar la robustez se emplea validación cruzada estratificada de cinco pliegues, reportando promedio y desviación estándar de exactitud y AUC. Finalmente, se ejecuta validación Leave-One-Out sobre todo el conjunto para analizar el impacto de cada muestra individual [10, 11]. Las métricas complementarias incluyen sensibilidad, especificidad, precisión, F1 y curva ROC. En escenarios clínicos, la sensibilidad se interpreta como la capacidad de detectar correctamente pacientes con anemia falciforme, mientras que la especificidad refleja la probabilidad de clasificar como sanas a las células normales. Los resultados se guardan en archivos CSV y se representan con figuras generadas automáticamente en la carpeta **results**.

Como parte del flujo de trabajo, cada ejecución genera un resumen textual que contextualiza las métricas y ofrece recomendaciones sobre umbrales operativos, aportando evidencia adicional para la toma de decisiones clínicas.

Para claridad, se emplean las definiciones estándar: la exactitud se calcula como $\text{Acc} = (\text{TP} + \text{TN}) / (\text{TP} + \text{TN} + \text{FP} + \text{FN})$, la sensibilidad como $\text{Sens} =$

$TP/(TP + FN)$ y la especificidad como $Esp = TN/(TN + FP)$. La métrica F1 se obtiene a partir de $2 \cdot Prec \cdot Sens / (Prec + Sens)$, donde *Prec* denota la precisión positiva. Para cada pliegue se almacenan tanto los valores puntuales como los intervalos de confianza a 95 %, estimados mediante bootstrap sobre las predicciones. Estos intervalos se reportan en el capítulo de resultados para contextualizar la variabilidad inherente a datasets pequeños.

4.9. Plan experimental y modos de ejecución

Los experimentos se organizaron en tres modos: rápido, completo y profundo. El modo rápido prioriza tiempos de respuesta cortos al limitar el número de características a 20 y desactivar la optimización exhaustiva de hiperparámetros; se utiliza durante el desarrollo y en verificaciones de integridad del pipeline. El modo completo mantiene los parámetros por defecto de ‘config.yaml’ y se emplea para corridas rutinarias con equilibrio entre tiempo de ejecución y profundidad analítica. El modo profundo amplía la búsqueda de hiperparámetros, aumenta el número de características a 50 y ejecuta validaciones adicionales como Leave-One-Out y análisis de estabilidad. Cada modo genera reportes etiquetados por fecha y sello horario que documentan el conjunto de configuraciones empleadas, los resultados obtenidos y las rutas de los artefactos generados, lo cual permite reproducir cualquier análisis y comparar iteraciones de manera sistemática.

La agenda experimental se gestiona mediante plantillas semanales donde se registran hipótesis, datos utilizados y responsables, lo que asegura trazabilidad y evita reutilizar sin control los mismos conjuntos de prueba.

4.10. Detección de anomalías

Una vez entrenado el clasificador, se ajusta un detector de anomalías basado en la distancia de Mahalanobis [13]. El modelo calcula la media y la matriz de covarianza sobre las características seleccionadas. El percentil 95 de las distancias observadas durante el entrenamiento define el umbral de activación. Cuando un holograma nuevo supera dicho valor, se marca como anomalía y se le asocia un *score* normalizado entre 0 y 1. Para aumentar la explicabilidad se generan rankings de contribución de cada característica a la anomalía, lo que ayuda a evaluar si la desviación proviene de texturas inusuales, cambios

geométricos o energía frecuencial atípica.

El conjunto externo de hologramas no sanguíneos se procesa en modo validación, registrando la distancia de Mahalanobis y la predicción del clasificador principal. Se espera que las muestras ajenas al dominio obtengan altas distancias y sean etiquetadas como anomalías, independientemente de la clase resultante. Esta prueba simula la presencia de polvo, células de otras especies o artefactos ópticos.

En un despliegue operativo, el umbral puede ajustarse en función de los requisitos de sensibilidad; por ello, el reporte incluye una tabla que sugiere valores alternativos y explica el impacto esperado en la tasa de falsos positivos.

4.11. Automatización e interfaz

Todas las etapas se encapsularon en una interfaz de línea de comandos documentada en `cli.py`. El usuario puede invocar modos rápidos, completos o profundos y generar reportes individuales de imágenes. El script `run_analysis.py` automatiza el pipeline completo, mientras que `example_single_prediction.py` ofrece una guía de uso programático. Los resultados se centralizan en la carpeta `results`, que almacena métricas, visualizaciones, reportes y el modelo entrenado. La documentación adicional se distribuye en archivos Markdown para acelerar la incorporación de nuevos colaboradores.

La arquitectura de la interfaz se organiza en comandos modulares y pruebas funcionales básicas que garantizan respuestas coherentes ante parámetros inválidos, lo que mejora la robustez del software y simplifica su mantenimiento.

4.12. Infraestructura de ejecución y reproducibilidad

Todos los experimentos se realizaron en un equipo de escritorio con procesador de ocho núcleos a 3,2 GHz, 16 GB de memoria RAM y sistema operativo basado en GNU/Linux. Se creó un entorno virtual de Python 3.13 para aislar dependencias y garantizar la portabilidad del proyecto. Las librerías principales incluyen NumPy, Pandas, scikit-learn, scikit-image, OpenCV, Matplotlib y Seaborn [27]. Cada versión de librería se documentó en el archi-

vo `requirements.txt` y se verificó su compatibilidad antes de ejecutar los experimentos finales.

Se empleó control de versiones con Git para rastrear cambios y se generaron etiquetas asociadas a hitos claves (prototipo inicial, optimización de hiperparámetros, integración del detector de anomalías). Los reportes automáticos se almacenan con marcas temporales, lo que facilita reconstruir el estado del sistema en un momento determinado. Para reforzar la reproducibilidad, se fijaron semillas de aleatoriedad en scikit-learn y NumPy.

Además, se documentó un procedimiento para recrear el entorno mediante contenedores ligeros o servicios en la nube, de modo que colaboradores externos puedan replicar los experimentos sin depender del hardware local.

4.13. Gestión de riesgos y calidad

La metodología incorporó puntos de control para mitigar riesgos experimentales. Antes de cada ejecución se validó la integridad del dataset unificado y se verificó la disponibilidad de espacio en disco para almacenar resultados. Una suite de pruebas unitarias sencillas comprobó la correcta creación del cache y la respuesta del detector ante entradas simuladas. Asimismo, los resultados anómalos detectados durante las fases piloto se documentaron en un cuaderno electrónico que acompaña este repositorio. Se mantiene un plan de mejora continua que prioriza riesgos críticos, revisa periódicamente el rendimiento y propone acciones de mitigación cuando se detectan desviaciones en métricas clave.

Capítulo 5

Desarrollo experimental y de ingeniería

Este capítulo detalla el proceso de construcción del sistema, las decisiones de diseño adoptadas durante la implementación y las iteraciones realizadas para alcanzar un pipeline robusto y reproducible.

5.1. Estructura del repositorio

El proyecto se organizó siguiendo principios de ingeniería de software reproducible. La raíz del repositorio contiene un archivo `cli.py` que centraliza las operaciones de entrenamiento, validación y análisis individual. La carpeta `src` alberga tres módulos principales: `hologram_analysis.py`, que implementa el flujo de procesamiento y las rutinas de entrenamiento; `anomaly_detector.py`, que encapsula el cálculo de la distancia de Mahalanobis y las funciones de interpretación; y `dataset_unifier.py`, responsable de crear el dataset unificado a partir de las colecciones originales. Adicionalmente, se proveen scripts utilitarios como `run_analysis.py` para ejecutar el pipeline completo con un solo comando y archivos de ejemplo para análisis de imágenes individuales.

La carpeta `data` aloja las colecciones originales y el dataset unificado generado. Para asegurar trazabilidad, cada ejecución del unificador crea un archivo resumen con el número de imágenes procesadas, las dimensiones promedio

y el tiempo insumido en cada fase. La carpeta **results** mantiene modelos entrenados, métricas en formato CSV, reportes de texto y figuras. Finalmente, el directorio **holograms** contiene las muestras externas empleadas para evaluar la detección de anomalías. Esta disposición facilita el seguimiento de versiones y la integración de nuevos experimentos.

5.2. Diseño del pipeline

El flujo de trabajo del sistema se compone de nueve etapas principales:

1. Lectura de la configuración desde **config.yaml**, donde se definen parámetros como modo de ejecución, número máximo de características y opciones de visualización.
2. Verificación de la existencia del dataset unificado; en caso negativo, se invoca automáticamente el módulo de unificación.
3. Carga de hologramas y etiquetas mediante estructuras **pandas** para asegurar trazabilidad.
4. Extracción de características y almacenamiento en cache. Si los archivos ya existen, se reutilizan para acelerar futuras ejecuciones.
5. Normalización de características y selección de atributos relevantes según el modo operativo.
6. Entrenamiento de modelos base y ensamblaje de las predicciones.
7. Validación cruzada, cálculo de métricas y generación de interpretabilidades basadas en Cohen's d .
8. Generación de visualizaciones: matriz de confusión, curva ROC, comparativa de modelos y mapas de calor de contribuciones.
9. Entrenamiento o actualización del detector de anomalías y almacenamiento del archivo **anomaly_detector.pkl**.

Cada etapa produce registros detallados en consola y en archivos de log, lo que favorece el seguimiento de errores y el análisis post mortem. Las marcas temporales y los identificadores de ejecución se incorporan en los nombres de archivo para vincular métricas, modelos y visualizaciones.

5.3. Modos de operación

Se definieron tres modos para adaptarse a distintos escenarios de uso:

Modo rápido Selecciona hasta 20 características, deshabilita la optimización avanzada de hiperparámetros y limita la validación cruzada a parámetros conservadores. Se utiliza para pruebas preliminares y verificación de la integridad del pipeline.

Modo completo Mantiene la configuración por defecto del archivo `config.yaml`, que incluye optimización moderada de hiperparámetros, selección de 35 características y generación de visualizaciones detalladas.

Modo profundo Amplía la búsqueda de hiperparámetros, aumenta el número de características seleccionadas a 50 y activa iteraciones adicionales para evaluar la estabilidad de la selección. Este modo se emplea para obtener métricas finales y analizar la sensibilidad del modelo.

Estos modos se invocan desde la CLI mediante `python cli.py analyze -mode {quick, full, deep}` y pueden complementarse con argumentos como `-features` para fijar el número máximo de características o `-no-cache` para forzar la reconstrucción de descriptores. También se dispone de la opción `-show-config` para visualizar los parámetros activos antes de iniciar el análisis. Durante las pruebas documentadas en este trabajo se utilizaron los modos rápido y profundo para construir los análisis comparativos.

5.4. Automatización de reportes

El pipeline genera automáticamente un archivo `analysis_report.txt` con un resumen narrativo del desempeño del modelo, las características seleccionadas y las métricas principales. Los reportes individuales de imágenes incluyen datos de predicción, confianza, probabilidades por clase, tamaño de la imagen y ranking de características discriminativas. Las visualizaciones se guardan con sellos de tiempo para diferenciar ejecuciones y facilitar la trazabilidad.

5.5. Integración del detector de anomalías

El detector de Mahalanobis se entrena al finalizar el proceso de clasificación. Con el objetivo de evitar recalcular la matriz de covarianza en cada ejecución, el archivo serializado se almacena en `results/anomaly_detector.pkl`. Si el usuario ejecuta el pipeline nuevamente, el sistema intenta cargar el detector existente y únicamente lo recalcula cuando se modifican las características

o se detecta una inconsistencia. Esta decisión reduce tiempos de cómputo y asegura consistencia en las evaluaciones fuera de dominio.

Para evaluar organismos no sanguíneos se implementó el comando `python cli.py validate -image-dir ./holograms`. Esta función recorre cada subcarpeta, procesa hasta diez imágenes por categoría y genera un reporte consolidado con las distancias de Mahalanobis. El sistema etiqueta cada muestra como anomalía o no, registra la clase predicha por el ensamble y produce un mapa de calor que resume la distribución de distancias. El reporte en formato CSV incluye probabilidades por clase, distancia, p-value y contribuciones principales, lo que permite auditorías detalladas.

5.6. Consideraciones de desempeño

Durante las pruebas en un equipo con procesador de ocho núcleos y 16 GB de RAM, el modo rápido completó el análisis en menos de 30 segundos, mientras que el modo profundo tomó alrededor de tres minutos. El tiempo más demandante corresponde a la validación Leave-One-Out, que requiere entrenar el modelo 304 veces. Para mitigar este costo se habilitó el uso de múltiples núcleos mediante la librería `joblib`. Asimismo, las características se guardan en cache para evitar recálculos costosos.

5.7. Gestión de configuraciones

El archivo `config.yaml` centraliza parámetros clave como rutas de datos, tamaño de imagen objetivo, opciones de visualización y tolerancia de anomalías. Esta configuración se carga al iniciar el análisis y puede modificarse en tiempo de ejecución mediante la CLI. Registrar y versionar estos ajustes resulta fundamental para garantizar reproducibilidad y permitir comparaciones entre experimentos.

5.8. Retos enfrentados

Durante el desarrollo se afrontaron tres desafíos principales. Primero, la instalación de dependencias en entornos sin conexión directa obligó a encapsular el proyecto en entornos virtuales y documentar los pasos para su despliegue.

Segundo, el tamaño limitado del dataset demandó estrategias de validación conservadoras para evitar conclusiones optimistas. Tercero, la ausencia de parámetros ópticos exactos del montaje impidió modelar la respuesta del sistema mediante simulaciones físicas, por lo que se priorizaron análisis empíricos y comparaciones con literatura publicada. Cada reto se abordó reforzando la documentación, automatizando tareas repetitivas y registrando supuestos explícitos en los reportes.

5.9. Cronograma de iteraciones

El desarrollo se estructuró en cuatro fases. La primera comprendió la curaduría de datos y la creación del unificador, garantizando consistencia geométrica entre hologramas. La segunda se centró en la extracción de características y la construcción de prototipos de clasificación; en esta etapa se definieron los modos rápido y completo. La tercera correspondió a la integración del detector de anomalías y a la generación de reportes automatizados, mientras que la cuarta consolidó la documentación, la validación externa y la preparación del manuscrito. Cada fase quedó registrada mediante etiquetas de Git y actas semanales que describen avances, decisiones y tareas pendientes.

5.10. Pruebas automatizadas y verificación continua

Aunque el alcance del proyecto no incluye una batería de pruebas extensa, se implementaron verificaciones unitarias básicas para garantizar el correcto funcionamiento de funciones críticas, como la creación del cache, la carga de configuraciones y la detección de anomalías ante entradas sintéticas. Además, antes de cada corrida larga se ejecutó el modo rápido como “smoke test” para confirmar que no existían regresiones. Los resultados de estas pruebas se documentaron en el cuaderno electrónico del repositorio, lo que permitió rastrear incidentes y justificar cambios en parámetros.

5.11. Estrategia de empaquetado y despliegue

El código se distribuye como un paquete Python autocontenido. Se incluyen archivos `requirements.txt` y `environment.yml` para facilitar la recreación del entorno, además de instrucciones para ejecutar el proyecto dentro de un contenedor ligero. Esta estrategia acelera la transferencia a otros laboratorios y evita problemas comunes de dependencia. También se configuraron reglas de `.gitignore` para evitar versionar modelos pesados o datos sensibles, promoviendo buenas prácticas de gestión de información.

5.12. Documentación y soporte

Con el fin de facilitar la adopción por parte de nuevos investigadores, se redactaron guías en formato Markdown que explican la instalación de dependencias, la ejecución del pipeline y la interpretación de resultados. Se mantienen versiones en español y en inglés para favorecer colaboraciones internacionales. Cada guía enlaza a los comandos más relevantes y describe posibles errores comunes junto a sus soluciones.

Asimismo, se diseñó un flujo de soporte que registra incidencias técnicas y propuestas de mejora. Las incidencias se etiquetan según su impacto (crítico, mayor, menor) y se priorizan en reuniones semanales con el tutor del proyecto. Este mecanismo permitió detectar tempranamente problemas de compatibilidad de librerías y ajustar las configuraciones antes de realizar las corridas finales documentadas en este manuscrito.

Capítulo 6

Resultados y análisis

En este capítulo se presentan los hallazgos cuantitativos y cualitativos derivados de la ejecución del pipeline en los modos rápido y profundo, así como la evaluación del detector de anomalías sobre hologramas externos. Se incluyen tablas comparativas, visualizaciones clave y una discusión crítica del desempeño alcanzado.

6.1. Rendimiento del clasificador

La Tabla [6.1](#) resume las métricas principales obtenidas en los modos rápido y profundo. El modo rápido procesa 20 características seleccionadas y omite la optimización exhaustiva de hiperparámetros. Aun con estas restricciones, alcanza una exactitud del 95,1 % y un AUC de 0,989. El modo profundo expande la selección a 50 características, activa una búsqueda más amplia de hiperparámetros y ejecuta validación Leave-One-Out, logrando un AUC de 0,995 y una exactitud de prueba del 93,4 %. Aunque la exactitud baja levemente respecto al modo rápido, el análisis profundo ofrece varianzas menores y evidencia de estabilidad estadística.

Tabla 6.1: Comparativo de métricas globales por modo de ejecución.

Modo	Exactitud test	AUC ROC	CV Accuracy (media $\pm$ DE)	LOOCV Accuracy
Rápido	0,951	0,989	0,934 $\pm$ 0,020	—
Profundo	0,934	0,995	0,954 $\pm$ 0,013	0,974

El reporte generado por el modo profundo indica que el ensamble retiene un alto nivel de generalización incluso bajo esquemas de validación exigentes: la validación cruzada estratificada presenta desviaciones estándar inferiores al 2 %, y la validación Leave-One-Out comete 8 errores sobre 304 hologramas. Esta estabilidad sugiere que las características seleccionadas capturan patrones robustos y que la combinación de clasificadores evita sobreajustes graves.

Para profundizar en la estadística de los pliegues, la Tabla 6.2 recoge los promedios y desviaciones estándar de AUC y exactitud durante la validación cruzada, junto con el desempeño obtenido en LOOCV para el modo profundo.

Tabla 6.2: Resumen de validación cruzada y Leave-One-Out.

Modo	AUC CV (media $\pm$ DE)	Acc. CV (media $\pm$ DE)	LOOCV (Acc., errores)
Rápido	0,990 $\pm$ 0,007	0,934 $\pm$ 0,020	—
Profundo	0,992 $\pm$ 0,005	0,954 $\pm$ 0,013	0,974, 8/304

La consistencia entre los pliegues y el bajo número de errores en LOOCV son indicios de que el ensamble no depende de observaciones aisladas. Para cuantificar la incertidumbre, se calcularon intervalos de confianza mediante bootstrap, los cuales se discuten en la Sección 6.7.

La matriz de confusión correspondiente al modo profundo (Figura 6.1) muestra un equilibrio entre falsos positivos y falsos negativos. Los errores se concentran en hologramas con texturas casi circulares pero con leves irregularidades, lo que evidencia la dificultad de separar casos limítrofes aun con descriptores ricos. La curva ROC (Figura 6.2) evidencia un área bajo la curva de 0,995, equivalente a un clasificador que mantiene sensibilidad y especificidad superiores al 95 % para umbrales intermedios.




Figura 6.1: Matriz de confusión producida en el modo profundo.




Figura 6.2: Curva ROC del ensamble entrenado en modo profundo.

6.2. Importancia de características

El análisis de Cohen's d revela que la correlación GLCM, la extensión y la solidez son los descriptores más discriminativos, seguidos por la razón de área convexa y el primer momento de Hu. Estos resultados son coherentes con la física del fenómeno: las células falciformes generan patrones menos

compactos y con orientaciones preferenciales que alteran la solidez aparente del holograma, mientras que las células sanas conservan simetrías circulares.

La Figura 6.3 muestra la distribución de importancias calculada por el modelo, destacando cómo las características de textura (GLCM y LBP) se combinan con medidas morfológicas para explicar la decisión. El análisis se complementa con la Figura 6.4, donde se presenta el desempeño individual de cada clasificador respecto al ensamble, confirmando que la combinación ponderada supera consistentemente a los modelos por separado. La interpretación cualitativa confirma que el ensamble captura múltiples niveles de información, lo que reduce el riesgo de depender de un único descriptor.




Figura 6.3: Distribución de las características más discriminativas según Cohen's d .




Figura 6.4: Comparativa de desempeño entre los clasificadores base y el ensemble final.

6.3. Análisis estadístico complementario

Se calculó la desviación estándar de las probabilidades emitidas por el ensemble para cada muestra del conjunto de prueba. Las muestras correctamente clasificadas exhiben desviaciones menores a 0,08, lo que indica consenso entre los clasificadores base. En cambio, los falsos positivos y falsos negativos presentan desviaciones superiores a 0,15, señal de desacuerdo interno. Esta métrica permite priorizar la revisión manual de casos dudosos. Adicionalmente, se estimaron intervalos de confianza del 95 % mediante 1 000 remuestreos bootstrap, obteniendo para el modo profundo un rango de exactitud entre 91,8 % y 95,0 %, y de AUC entre 0,991 y 0,998. Estos intervalos se alinean con los valores reportados en las Tablas 6.1 y 6.2.


6.4. Validación fuera de dominio

La evaluación del detector de anomalías sobre el conjunto externo *holograms* produjo 30/30 detecciones positivas (100 %). Las distancias de Mahalanobis oscilaron entre 75,98 y 155,54, con una media de 110,85, muy por encima del umbral de 9,89 establecido durante el entrenamiento. La Tabla 6.3 resume las estadísticas por categoría y evidencia que el detector responde con distancias significativamente superiores al umbral establecido.

Tabla 6.3: Resultados de la detección de anomalías en el conjunto externo.

Categoría externa	Imágenes analizadas	Distancia media	Tasa de anomalías
<i>8 extunderscore Poaceae</i>	10	85,3	100 %
<i>2 extunderscore Aspergillus</i>	10	142,1	100 %
<i>3 extunderscore Diatom</i>	10	105,2	100 %

La Figura 6.5 ilustra la distribución de distancias registradas durante la validación externa. Cada punto está marcado con el score de anomalía normalizado, que alcanza el valor máximo de 1 para todos los casos. Este comportamiento evidencia que el detector distingue con claridad los hologramas fuera del dominio de eritrocitos, incluso cuando el clasificador principal asigna probabilidades altas a una de las clases entrenadas. El mapa de calor generado (Figura 6.6) ofrece una perspectiva adicional sobre la intensidad de las distancias en el espacio de características y permite identificar qué muestras se aproximan más al umbral a pesar de ser consideradas anomalías.

**Figura 6.5:** Distribución de distancias de Mahalanobis para muestras externas.




Figura 6.6: Mapa de calor de predicciones y distancias para organismos no sanguíneos.

6.5. Comparación con antecedentes

Las métricas obtenidas se contrastaron con reportes recientes de la literatura. Buitrago-Duque *et al.* documentaron precisiones cercanas al 90 % utilizando reconstrucción holográfica y clasificadores basados en redes neuronales [5]. O'Connor *et al.* alcanzaron AUC superiores a 0,97 en tareas holográficas con CNN, aunque con datasets más extensos y hardware especializado [7]. El desempeño del ensamble propuesto se sitúa dentro de ese rango, con la ventaja de que requiere menos datos, puede ejecutarse en CPU y ofrece interpretabilidad explícita. Además, la detección de anomalías no suele reportarse en estudios previos, por lo que constituye un valor añadido al prevenir clasificaciones espurias en presencia de contaminantes.

6.6. Sensibilidad a hiperparámetros

Se evaluó la influencia de parámetros clave mediante corridas controladas. Reducir el número máximo de características a 10 disminuye la exactitud en 3 puntos porcentuales, principalmente por la pérdida de información en los descriptores morfológicos. Incrementar el umbral de Mahalanobis al percentil 97,5 reduce los falsos positivos en datos externos, pero incrementa la probabilidad de aceptar hologramas no sanguíneos con probabilidades altas; por ello se mantuvo el percentil 95 como compromiso entre sensibilidad y especificidad. También se experimentó con pesos alternativos en la votación del ensamble, constatando que ponderar en función del AUC individual ofre-

ce un mejor balance que utilizar pesos uniformes. Estos análisis demuestran que el pipeline puede ajustarse a distintos contextos operativos sin sacrificar interpretabilidad.

6.7. Discusión

Los resultados confirman que la combinación de descriptores físicos y modelos clásicos es suficiente para alcanzar métricas competitivas sin recurrir a arquitecturas profundas. La pequeña brecha entre los modos rápido y profundo sugiere que la selección de características y la regularización controlan adecuadamente el sobreajuste. El modo profundo aporta evidencias adicionales al integrar LOOCV, lo cual respalda la robustez del sistema frente a la variabilidad del dataset.

En la práctica, la diferencia entre una exactitud del 95 % y del 93 % es marginal frente a la posibilidad de correr el pipeline en minutos o segundos dependiendo de la disponibilidad computacional. Por lo tanto, se recomienda utilizar el modo rápido durante fases exploratorias o cuando se deba evaluar continuamente nuevos hologramas, y reservar el modo profundo para reportes formales y calibraciones periódicas.

El detector de anomalías demostró ser particularmente útil al analizar muestras externas. La capacidad de denunciar hologramas ajenos al dominio evita que el sistema proporcione una clasificación errónea con alta confianza, un riesgo habitual en modelos puramente discriminativos [14]. Además, las contribuciones por característica permiten al usuario verificar qué tipo de patrones desencadenan la alerta, habilitando decisiones clínicas más informadas.

La evaluación bootstrap y el análisis de desviaciones estándar entre clasificadores base sugieren que el ensamble mantiene un consenso alto para la mayoría de las muestras; los casos conflictivos pueden priorizarse para revisión manual o para enriquecer el dataset con nuevas anotaciones. Esta información se alinea con la literatura que recomienda monitorear la calibración y la incertidumbre antes de desplegar sistemas de apoyo diagnóstico [12].

Finalmente, las visualizaciones integradas—matriz de confusión, curvas ROC, histogramas de características y comparativas de modelos—constituyen una base sólida para documentar procesos de validación y cumplir con estándares de trazabilidad. Estas herramientas facilitan la comparación con trabajos

previos y con futuras versiones del sistema.

Capítulo 7

Conclusiones y trabajo futuro

La presente investigación demuestra que la clasificación de hologramas de eritrocitos sin reconstrucción digital es viable cuando se combina una representación física rica con algoritmos de aprendizaje automático interpretables. Los principales hallazgos se resumen a continuación:

1. El ensamble de clasificadores propuesto alcanzó métricas competitivas en evaluación cruzada (AUC superior a 0,99 y exactitud de 0,95 en modo rápido), lo que confirma la potencia de los descriptores de textura, frecuencia y morfología para discriminar entre células sanas y falciformes.
2. La validación Leave-One-Out del modo profundo registró una precisión del 97,4%, lo que aporta evidencia estadística de la estabilidad del sistema aun en escenarios de datos limitados. Este resultado se alinea con recomendaciones recientes sobre validación rigurosa en muestras pequeñas [10, 11].
3. El detector de anomalías basado en la distancia de Mahalanobis identificó correctamente todos los hologramas externos de organismos no sanguíneos, indicando que el sistema puede advertir al usuario cuando enfrenta entradas fuera de su dominio de entrenamiento.
4. La implementación de una interfaz de línea de comandos automatizada incrementa la reproducibilidad y facilita la adopción del sistema en laboratorios con recursos modestos, al tiempo que documenta cada experimento mediante reportes y visualizaciones.

Limitaciones

A pesar de los resultados promisorios, el estudio presenta limitaciones. El tamaño del dataset restringe la posibilidad de explorar modelos con mayor complejidad y dificulta la estimación de intervalos de confianza estrechos. La ausencia de parámetros ópticos detallados impide realizar simulaciones para complementar la evidencia empírica. Tampoco se evaluó la sensibilidad del sistema ante variaciones severas de iluminación o ante hologramas obtenidos con otros sensores, por lo que la generalización debe confirmarse en escenarios clínicos adicionales. Estas limitaciones orientan las líneas de trabajo futuro descritas a continuación.

Trabajo futuro

A partir de los resultados obtenidos se identifican múltiples líneas de investigación:

- **Caracterización óptica.** Registrar parámetros exactos del montaje DLHM (distancias, aperturas, espectro de la fuente) permitiría correlacionar de forma cuantitativa las características seleccionadas con la física del sistema y facilitaría simulaciones numéricas que sirvan para ampliar el dataset sintéticamente.
- **Expansión del dataset.** Incluir hologramas capturados en múltiples centros clínicos, bajo diversas condiciones ambientales y con otras patologías hemolíticas ayudaría a evaluar la capacidad de generalización y a entrenar modelos multiclase.
- **Modelos híbridos.** Explorar arquitecturas que combinen redes neuronales ligeras con descriptores físicos podría mejorar la sensibilidad ante patrones sutiles sin sacrificar interpretabilidad [12].
- **Integración clínica.** Desplegar el sistema en entornos de telemedicina requerirá desarrollar interfaces gráficas y protocolos de aseguramiento de calidad, así como evaluar factores éticos y de protección de datos.
- **Detección temprana.** Analizar la sensibilidad del detector de anomalías frente a variaciones graduales de morfología celular permitiría establecer umbrales de alerta temprana y estudiar transiciones entre estados fisiopatológicos.

En síntesis, el trabajo presentado sienta las bases para un diagnóstico portátil

CONCLUSIONES Y TRABAJO FUTURO

y transparente de anemia falciforme mediante holografía digital. El enfoque adoptado equilibra rigurosidad física, solidez estadística y accesibilidad tecnológica, y abre la puerta a futuras investigaciones que profundicen en la integración de óptica computacional y aprendizaje automático interpretable.

Bibliografía

- [1] W. A. Arishi, H. A. Alhadrami, and M. Zourob, “Techniques for the detection of sickle cell disease: A review,” *Micromachines*, vol. 12, no. 5, p. 453, 2021.
- [2] P. T. McGann and C. Hoppe, “The pressing need for point-of-care diagnostics for sickle cell disease: A review of current and future technologies,” *Blood Cells, Molecules, and Diseases*, vol. 67, pp. 104–113, 2017.
- [3] P. Shrestha *et al.*, “Evaluation of low-cost techniques to detect sickle cell disease and β -thalassemia: an open-label, international, multicentre study,” *The Lancet Regional Health – Southeast Asia*, vol. 15, p. 100356, 2025.
- [4] S. Amann, M. von Witzleben, and S. Breuer, “3d-printable portable open-source platform for low-cost lens-less holographic cellular imaging,” *Scientific Reports*, vol. 9, pp. 1–9, 2019.
- [5] C. Buitrago-Duque, B. P. no Jurado, and J. Garcia-Sucerquia, “Robust and compact digital lensless holographic microscope for label-free blood smear analysis,” *HardwareX*, vol. 14, p. e00428, 2023.
- [6] J. Kim *et al.*, “Single-shot three-dimensional morphology of biological cells in digital holographic microscopy using a physics-driven neural network,” *Nature Communications*, vol. 16, p. 1123, 2025.
- [7] T. O’Connor *et al.*, “Deep learning-based cell identification and disease diagnosis using spatio-temporal cellular dynamics in compact digital holographic microscopy,” *Biomedical Optics Express*, vol. 11, no. 2, pp. 1225–1242, 2020.

- [8] H. Sazak and M. Kotan, “Automated blood cell detection and classification in microscopic images using yolov11,” *Diagnostics*, vol. 14, no. 1, p. 52, 2024.
- [9] L. Alzubaidi *et al.*, “Deep learning models for classification of red blood cells in microscopy images to aid in sickle cell anemia diagnosis,” *Electronics*, vol. 9, no. 3, p. 427, 2020.
- [10] A. Vabalas, E. Gowen, E. Poliakoff, and A. J. Casson, “Machine learning algorithm validation with a limited sample size,” *PLOS ONE*, vol. 14, no. 11, p. e0224365, 2019.
- [11] I. Tsamardinos *et al.*, “Don’t lose samples to estimation,” *Patterns*, vol. 3, no. 7, p. 100568, 2022.
- [12] J. Montero *et al.*, “Explainable machine learning in medical imaging: From theory to clinical practice,” *IEEE Access*, vol. 12, pp. 123 456–123 478, 2024.
- [13] P. C. Mahalanobis, “On the generalised distance in statistics,” *Proceedings of the National Institute of Sciences of India*, vol. 2, no. 1, pp. 49–55, 1936.
- [14] P. J. Rousseeuw *et al.*, “Anomaly detection by robust statistics,” *Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery*, vol. 9, no. 2, p. e1233, 2019.
- [15] U. EAFIT, “Reglamento de propiedad intelectual,” 2018, accedido: sep. 16, 2025. [Online]. Available: <https://www.eafit.edu.co/institucional/reglamentos/Documents/reglamento-propiedad-intelectual-enero-2018-1.pdf>
- [16] A. Greenbaum, W. Luo, and A. Ozcan, “Wide-field computational imaging of pathology slides using lens-free on-chip microscopy,” *Science Translational Medicine*, vol. 6, no. 267, p. 267ra175, 2014.
- [17] S. Barburiceanu, R. Terebes, and S. Meza, “3d texture feature extraction and classification using glcm and lbp-based descriptors,” *Applied Sciences*, vol. 11, no. 4, p. 1679, 2021.
- [18] G. Dheepak *et al.*, “Brain tumor classification: a novel approach integrating glcm, lbp and composite features,” *Frontiers in Oncology*, vol. 13, p. 117234, 2023.

- [19] B. B. Singh *et al.*, “Efficient medical image enhancement using clahe,” *International Journal of Computer Applications*, vol. 162, no. 6, pp. 11–15, 2017.
- [20] C. M. Bishop, *Pattern Recognition and Machine Learning*. New York, NY, USA: Springer, 2006.
- [21] S. Alagu *et al.*, “A novel deep learning approach for sickle cell anemia detection in human RBCs using an improved wrapper-based feature selection technique in microscopic blood smear images,” *Biomedizinische Technik*, vol. 67, no. 5, pp. 485–495, 2022.
- [22] M. Darrin *et al.*, “Classification of red cell dynamics with convolutional and recurrent neural networks: a sickle cell disease case study,” *Scientific Reports*, vol. 13, p. 9124, 2023.
- [23] D. W. Hosmer, S. Lemeshow, and R. X. Sturdivant, *Applied Logistic Regression*, 3rd ed. Hoboken, NJ, USA: Wiley, 2013.
- [24] L. Breiman, “Random forests,” *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.
- [25] J. H. Friedman, “Greedy function approximation: A gradient boosting machine,” *Annals of Statistics*, vol. 29, no. 5, pp. 1189–1232, 2001.
- [26] I. Goodfellow, Y. Bengio, and A. Courville, “Deep learning,” *MIT Press*, 2016.
- [27] F. Pedregosa *et al.*, “Scikit-learn: Machine learning in Python,” *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.