

UNIVERSIDAD EAFIT
Escuela de Ciencias Aplicadas e Ingeniería
Programa de Ingeniería Física

Sistema de clasificación de hologramas de glóbulos
rojos para la detección de anemia falciforme basado en
aprendizaje automático interpretable

Trabajo de grado

Autor: Santiago Ochoa Villegas
Tutor: Carlos Alejandro Trujillo

Medellín, Colombia
2025

Contenido

1. Introducción	9
2. Planteamiento del problema	14
2.1. Contexto y brecha diagnosticada	14
2.2. Pregunta de investigación	14
2.3. Objetivos	15
2.4. Alcance y delimitaciones	15
2.5. Limitaciones y riesgos	16
2.6. Hipótesis y productos esperados	16
3. Marco teórico	17
3.1. Formación del holograma y modelos de propagación	17
3.2. Representación matemática de texturas holográficas	19
3.3. Modelación estadística de los clasificadores	23
3.4. Detección de anomalías, calibración e incertidumbre	26
3.5. Integración interdisciplinaria, ética y líneas de investigación . .	27
4. Metodología	29
4.1. Datos, gobernanza y normalización	29
4.2. Extracción de descriptores físicos y estadísticos	30
4.3. Modelado, validación y calibración	32
4.4. Incertidumbre, anomalías y reproducibilidad operativa	33
5. Desarrollo experimental y de ingeniería	35
5.1. Arquitectura funcional y flujo	35
5.2. Automatización, trazabilidad y aseguramiento de calidad	36

6. Resultados y análisis	38
6.1. Desempeño del modelo y separabilidad de las características .	38
6.2. Matriz de confusión y curva ROC	40
6.3. Detección de anomalías y estructura del espacio de caracterís- ticas	42
6.4. Incertidumbre, calibración y robustez estadística	44
6.5. Análisis de errores y discusión	44
7. Conclusiones y trabajo futuro	46

Lista de Figuras

3.1.	Transformaciones clave aplicadas sobre un holograma falciforme: interferograma original, magnitud logarítmica de la transformada de Fourier, mapa uniforme de LBP, respuesta de un filtro de Gabor, energía combinada de coeficientes wavelet y matriz de coocurrencia GLCM normalizada.	20
3.2.	Comparativa de descriptores entre un holograma sano (fila superior) y uno falciforme (fila inferior). Cada columna exhibe el holograma original, el histograma LBP, la energía espectral por anillos de Fourier y la energía acumulada de los coeficientes wavelet.	22
6.1.	Distribuciones empíricas de las características más discriminativas. Cada panel compara clases sanas (azul) y falciformes (naranja) en pares de atributos; las líneas punteadas marcan medias por clase.	39
6.2.	Matriz de confusión normalizada para el conjunto de prueba. .	40
6.3.	Curva ROC del modelo final con el área bajo la curva correspondiente.	41
6.4.	Proyección t-SNE del espacio de características, coloreada por distancia de Mahalanobis.	43
6.5.	Exactitud con intervalos bootstrap y curva de confiabilidad del modelo final.	44

Lista de Tablas

6.1. Métricas del modelo final en el conjunto de prueba y en validación cruzada.	38
6.2. Resultados de la detección de anomalías en el repositorio externo.	42

Resumen

La anemia falciforme continúa siendo una condición hemoglobinopática de alto impacto social y clínico, especialmente en regiones donde el acceso a laboratorios especializados resulta limitado. Las metodologías diagnósticas estándar cromatografía líquida de alta resolución (HPLC) o la electroforesis dependen de equipamiento costoso, procesos de tinción y personal altamente entrenado, lo que retrasa campañas de cribado masivo en comunidades vulnerables. En respuesta a esta brecha, el presente trabajo de grado propone un sistema de clasificación automatizado que analiza hologramas generados mediante microscopía digital sin lentes. La hipótesis sostiene que, aun sin reconstruir el campo óptico, es posible discriminar entre glóbulos rojos sanos y células falciformes si se combinan descriptores de textura, forma y frecuencia con modelos de aprendizaje automático clásicos y un módulo de detección de anomalías. Permitiendo así eliminar la parte más costosa computacionalmente del proceso de clasificación que es la reconstrucción en fase

El estudio parte de un conjunto de 304 hologramas rotulados (151 sanos y 153 enfermos) y de un repositorio de validación externa compuesto por hologramas de organismos ajenos a la sangre. Ambos datasets fueron proporcionados por el semillero de óptica y fotónica de la Universidad EAFIT. La metodología abarca la unificación automatizada de bases heterogéneas, la extracción de 84 características físicas y estadísticas, la selección de atributos relevantes y la construcción de un ensamble de clasificadores compuesto por regresión logística, máquinas de soporte vectorial, bosques aleatorios y gradiente por potenciación. Se integró, además, un detector de anomalías basado en la distancia de Mahalanobis para identificar muestras fuera de dominio y complementar la interpretación de las decisiones del modelo principal.

El pipeline se implementó en una interfaz de línea de comandos reproduci-

ble con un único perfil operativo que encapsula la unificación de datos, el entrenamiento del ensamble y la detección de anomalías. Las campañas experimentales alcanzaron una exactitud de prueba del 95,1 % y un área bajo la curva ROC de 0,989, asistidas por validación cruzada estratificada, análisis Leave-One-Out y estimaciones bootstrap de incertidumbre. Asimismo, la detección de anomalías etiquetó correctamente el 100 % de los hologramas no sanguíneos. Los resultados demuestran que la sinergia entre óptica computacional y aprendizaje automático interpretable habilita soluciones de diagnóstico portátiles, transparentes y escalables.

Palabras clave: anemia falciforme, microscopía holográfica sin lente, aprendizaje automático interpretable, detección de anomalías, análisis de patrones.

Abstract

Sickle cell disease remains a high-impact hemoglobinopathy, particularly in regions where specialized laboratories are scarce. Conventional diagnostics depend on costly instrumentation, chemical staining, and expert cytotechnologists, which hinders timely screening. This thesis introduces an automated system that classifies holograms captured with lensless digital holographic microscopy. The guiding hypothesis is that raw interference patterns contain enough discriminative cues to separate healthy erythrocytes from sickled cells when texture, morphology, and frequency descriptors are combined with classic interpretable machine-learning models and an anomaly detection layer.

The study is grounded on a curated dataset of 304 labeled holograms (151 healthy, 153 sickle cell) and an external repository of non-blood specimens. The methodology encompasses automatic dataset unification, extraction of 84 physics-inspired features, feature selection, and the construction of an ensemble that blends logistic regression, support vector machines, random forests, and gradient boosting classifiers. An anomaly detector based on the Mahalanobis distance complements the ensemble by flagging out-of-distribution samples and providing interpretable evidence for extreme cases.

The end-to-end pipeline is delivered as a reproducible command-line interface with a single operational profile that encapsulates dataset curation, feature extraction, model training, and anomaly detection. Experimental campaigns reached a test accuracy of 95.1 % and a ROC-AUC of 0.989, leveraging stratified cross-validation, Leave-One-Out analyses, and bootstrap estimation of uncertainty. The anomaly detector correctly identified 100 % of the non-blood holograms. These outcomes demonstrate that the synergy between computational optics and interpretable machine learning enables portable, transparent, and scalable diagnostic solutions.

Keywords: sickle cell disease, lensless digital holographic microscopy, interpretable machine learning, anomaly detection, pattern analysis.

Capítulo 1

Introducción

La anemia falciforme constituye uno de los desafíos más significativos en salud pública global, representando una hemoglobinopatía hereditaria de alta carga sanitaria que compromete fundamentalmente el transporte de oxígeno en el organismo. Esta condición patológica ocasiona crisis vaso-oclusivas recurrentes que deterioran progresivamente la calidad de vida del paciente y reduce considerablemente la expectativa de vida de la población afectada. Las estimaciones epidemiológicas globales señalan más de 300.000 nacimientos anuales con la enfermedad, manifestando una prevalencia particularmente sostenida en regiones tropicales y subtropicales donde persiste la ventaja heterocigota frente a la malaria, un fenómeno evolutivo que ha mantenido la frecuencia del alelo mutante en estas poblaciones [1]. Esta distribución geográfica específica coincide precisamente con las regiones que presentan mayores limitaciones en infraestructura sanitaria, creando una paradoja donde la mayor incidencia de la enfermedad se concentra en las áreas con menor capacidad diagnóstica y terapéutica.

Las estrategias diagnósticas vigentes para la detección de anemia falciforme, que abarcan desde los tradicionales frotis sanguíneos teñidos hasta técnicas más sofisticadas como la cromatografía líquida de alta resolución (HPLC) y la electroforesis de hemoglobina, ofrecen niveles de sensibilidad y especificidad elevados que pueden superar el 95 en condiciones óptimas. Sin embargo, estas metodologías demandan laboratorios especializados con equipamiento costoso, personal altamente entrenado en técnicas de laboratorio clínico, y cadenas de suministro estables para reactivos y consumibles especializados,

elementos que raramente convergen de manera sostenible en entornos rurales o con recursos limitados [2, 3]. Esta dependencia crítica de infraestructura compleja no solo retrasa significativamente la implementación de programas de cribado neonatal universal, sino que también compromete la continuidad del tratamiento y el seguimiento longitudinal de pacientes en países de ingresos bajos y medios, donde se concentra aproximadamente el 75

En este contexto de necesidad crítica, la microscopía digital holográfica sin lente (DLHM, por sus siglas en inglés) surge como una plataforma óptica innovadora y asequible que revoluciona el paradigma tradicional de la microscopía. Esta tecnología emplea fuentes de luz coherente económicas, como diodos láser o LEDs parcialmente coherentes, combinadas con sensores de imagen comerciales ampliamente disponibles para registrar patrones de interferencia complejos en una sola captura, eliminando completamente la necesidad de lentes objetivos costosos y sistemas de alineación precisos [4, 5]. Al operar en el régimen de difracción de Fresnel, el montaje experimental preserva tanto la información de fase como de amplitud en el holograma digital registrado, y habilita reconstrucciones numéricas posteriores de alta calidad cuando se dispone de los parámetros geométricos del sistema debidamente caracterizados [6, 7]. No obstante, la reconstrucción convencional de estos hologramas digitales exige la implementación de transformadas de Fourier computacionalmente costosas, algoritmos iterativos de propagación de campo, y una caracterización meticulosa de distancias de propagación y dimensiones de aperturas que puede resultar técnicamente desafiante en entornos no especializados. La propuesta innovadora de clasificar directamente los hologramas sin necesidad de reconstrucción evita dichas restricciones técnicas y computacionales, reduce drásticamente el tiempo de procesamiento de minutos a segundos, y conserva íntegra la rica información interferométrica relevante para describir las morfologías anómalas características de los eritrocitos falciformes.

El vertiginoso auge de las técnicas de aprendizaje automático en la última década ha impulsado el desarrollo de soluciones computacionales sofisticadas para hematología digital que abarcan un amplio espectro tecnológico, desde arquitecturas neuronales profundas de gran escala con millones de parámetros hasta esquemas híbridos que combinan extracción manual de descriptores morfológicos con clasificadores de última generación [8, 9, 10]. Aunque estos modelos de vanguardia alcanzan métricas de rendimiento notables que pueden superar el 98 de precisión en conjuntos de validación controlados,

su adopción clínica práctica se ve severamente limitada por la necesidad de grandes volúmenes de datos anotados para entrenamiento, la opacidad inherente de sus procesos decisionales que dificulta la interpretación médica, y los requerimientos computacionales que exceden las capacidades disponibles en muchos entornos clínicos. Revisiones sistemáticas recientes enfatizan la pertinencia crítica de metodologías interpretables que puedan ser validadas rigurosamente en muestras pequeñas mediante protocolos estadísticos robustos, así como el reporte sistemático y transparente de métricas de incertidumbre y calibración que permitan evaluar la confiabilidad de las predicciones [11, 12, 13]. En consecuencia, resulta estratégico desde una perspectiva de implementación clínica priorizar descriptores físicos comprensibles basados en principios ópticos establecidos y clasificadores clásicos bien caracterizados que mantengan un equilibrio óptimo entre desempeño diagnóstico, trazabilidad de decisiones, y coste computacional accesible.

El presente proyecto de investigación se apoya en un repositorio propio meticulosamente curado de 304 hologramas digitales rotulados por expertos hematólogos, compuesto por 151 muestras de individuos sanos y 153 muestras confirmadas con anemia falciforme mediante técnicas gold standard. Este conjunto de datos principal se complementa estratégicamente con 30 hologramas externos de organismos no sanguíneos, incluyendo microalgas, polen y otros especímenes biológicos, que representan escenarios fuera de dominio cruciales para evaluar la robustez del sistema. Sobre esta base experimental se diseña un pipeline modular altamente configurable que unifica los diversos orígenes de datos mediante protocolos estandarizados, normaliza la geometría de los hologramas para garantizar consistencia en el procesamiento, y extrae sistemáticamente 84 características cuantitativas de textura, frecuencia y morfología inspiradas en fenómenos físicos bien establecidos en la literatura óptica. El sistema implementado entrena un ensamble sofisticado de clasificadores lineales y basados en árboles de decisión, integra esquemas de validación cruzada estratificada y Leave-One-Out para gestionar eficientemente la limitada disponibilidad de muestras clínicas, e incorpora un detector de anomalías robusto soportado en la distancia de Mahalanobis para identificar muestras atípicas o fuera de distribución [14, 15]. Todo el conjunto de herramientas se encapsula en una interfaz de línea de comandos reproducible y documentada que automatiza el flujo completo del modelo final, genera reportes estandarizados en formatos múltiples, y facilita la auditoría exhaustiva de resultados por parte de personal clínico y técnico.

El tratamiento completamente digital de hologramas fomenta significativamente la colaboración científica internacional al permitir que los modelos entrenados, scripts de procesamiento, y conjuntos de datos derivados puedan compartirse con facilidad a través de repositorios en línea y plataformas de colaboración. La documentación exhaustiva de dependencias de software, procedimientos detallados de ejecución, y bitácoras completas de experimentos incrementa sustancialmente la capacidad de replicación independiente y acelera la validación cruzada por parte de otras instituciones académicas y centros de investigación [8]. El repositorio asociado a este trabajo consolida de manera organizada el código fuente completo, archivos de configuración parametrizables, y guías operativas bilingües en español e inglés, en estricta consonancia con las directrices de propiedad intelectual y difusión del conocimiento establecidas por la Universidad EAFIT [16]. Este compromiso institucional con los principios de ciencia abierta busca deliberadamente allanar el camino hacia ensayos clínicos multicéntricos de mayor escala y facilitar la transferencia tecnológica efectiva hacia iniciativas concretas de telemedicina en contextos de bajos recursos, donde el impacto potencial de estas tecnologías es máximo.

Los aportes sustanciales del presente estudio se concentran en cuatro frentes metodológicos articulados entre sí que constituyen una contribución integral al campo. En primer lugar, se expone un marco teórico comprehensivo que relaciona sistemáticamente los fundamentos ópticos de DLHM con los requisitos clínicos específicos del diagnóstico de anemia falciforme, resaltando las implicaciones técnicas y prácticas de trabajar directamente con hologramas sin reconstrucción numérica. En segundo lugar, se documenta exhaustivamente un pipeline reproducible de procesamiento que automatiza la extracción de características discriminantes, implementa esquemas de validación estadísticamente rigurosos, y genera visualizaciones interpretables del modelo final que facilitan la comprensión clínica. En tercer lugar, se demuestra experimentalmente mediante análisis cuantitativos que un ensamble cuidadosamente diseñado de clasificadores clásicos puede lograr métricas competitivas con una fracción mínima del costo computacional asociado a alternativas de mayor complejidad arquitectónica, sin sacrificar la interpretabilidad esencial para la adopción clínica. Finalmente, se implementa un detector de anomalías innovador que robustece significativamente la toma de decisiones al señalar proactivamente entradas fuera de dominio y justificar la alerta mediante contribuciones cuantificables por característica, proporcionando así un

mecanismo de seguridad crítico para aplicaciones clínicas.

El manuscrito se organiza sistemáticamente de la siguiente manera para presentar de forma coherente el desarrollo completo del proyecto. El Capítulo 2 delimita con precisión la pregunta de investigación central, establece los objetivos específicos y generales, y define claramente el alcance y las limitaciones del estudio. El Capítulo 3 desarrolla exhaustivamente el sustento teórico necesario, cubriendo tanto los principios fundamentales de óptica holográfica como los conceptos esenciales de inteligencia artificial aplicada al diagnóstico médico. El Capítulo 4 describe detalladamente la metodología experimental empleada para construir, entrenar y validar el sistema propuesto, incluyendo protocolos de adquisición de datos y esquemas de evaluación. El Capítulo 5 resume las decisiones críticas de ingeniería de software, documenta la arquitectura modular del repositorio, y presenta las consideraciones de implementación práctica. El Capítulo 6 analiza cuantitativamente los hallazgos experimentales obtenidos, evalúa el rendimiento del detector de anomalías, y discute las implicaciones clínicas de los resultados. Por último, el Capítulo 7 presenta las conclusiones generales del estudio, identifica las limitaciones actuales del enfoque propuesto, y delinea las líneas prometedoras de trabajo futuro que podrían expandir el impacto de esta investigación.

Capítulo 2

Planteamiento del problema

2.1. Contexto y brecha diagnosticada

El diagnóstico de anemia falciforme en entornos de bajos recursos enfrenta tensiones entre exactitud clínica y viabilidad operativa. Técnicas consolidadas como la cromatografía líquida de alta resolución, la electroforesis y los ensayos moleculares exhiben sensibilidad y especificidad elevadas, pero su despliegue exige infraestructura especializada, consumibles costosos y personal altamente entrenado, lo que limita la cobertura de programas de cribado en regiones con mayor carga de enfermedad [2, 3, 1]. En ese panorama, la microscopía holográfica digital sin lentes (DLHM) emerge como una alternativa atractiva por su hardware simple y de bajo costo, capaz de capturar información rica en fase y amplitud; sin embargo, la clasificación automática directamente desde hologramas—sin reconstrucción numérica—sigue siendo un reto abierto que demanda metodologías de procesamiento y aprendizaje robustas [4, 5, 8].

2.2. Pregunta de investigación

A partir de esta brecha se define la pregunta que orienta el proyecto: *¿es posible desarrollar un sistema de clasificación basado en hologramas DLHM y aprendizaje automático que pueda diferenciar entre glóbulos rojos sanos y falciformes a partir de sus hologramas sin reconstruir?* Esta formulación

delimita explícitamente el dominio (eritrocitos), la modalidad de adquisición (DLHM) y la restricción metodológica clave (ausencia de reconstrucción), y establece el objetivo de alcanzar desempeño clínicamente útil en un flujo de trabajo computacional eficiente [4, 5, 8].

2.3. Objetivos

El propósito general es *desarrollar un sistema de clasificación de hologramas de microscopía sin lentes para glóbulos rojos, basado en técnicas de aprendizaje automático, orientado a la detección de anemia falciforme* [4, 5, 8]. Para concretarlo, el trabajo se estructura en tres frentes integrados. Primero, se establece un *pipeline* de preprocesamiento para hologramas DLHM que comprende conversión a escala de grises, redimensionamiento a 512×512 512×512 píxeles, normalización de intensidad y realce de contraste mediante técnicas locales (p.ej., tipo CLAHE), incorporando filtrado en frecuencia cuando sea pertinente con el fin de optimizar la calidad de entrada para los modelos [4, 5]. Luego, se evalúa el desempeño de diversas arquitecturas de aprendizaje automático en el escenario de clasificación *sin reconstrucción*, adoptando un enfoque clásico sustentado en la extracción de descriptores de textura, forma y contenido frecuencial del holograma, y comparando clasificadores representativos bajo un protocolo experimental controlado [8, 5]. Finalmente, se valida rigurosamente el sistema mediante esquemas de validación cruzada anidada y procedimientos estadísticos que reduzcan el sesgo por tamaño muestral y eviten *overfitting*, reportando métricas estándar de evaluación (área bajo la curva ROC, precisión balanceada, sensibilidad y especificidad) con estimaciones de incertidumbre reproducibles [11, 12].

2.4. Alcance y delimitaciones

El estudio se circunscribe a la tarea de clasificación binaria de hologramas DLHM de eritrocitos en dos categorías—sanos y falciformes—sin realizar reconstrucción digital del campo complejo. No se aborda el diseño ni la optimización del montaje óptico, la segmentación celular individual, la integración con historias clínicas electrónicas ni la evaluación de patologías hematológicas distintas a la anemia falciforme. El desarrollo computacional se implementa en Python y se orienta a ejecutarse en recursos de cómputo moderados, prio-

rizando la reproducibilidad experimental y la trazabilidad del flujo de datos [4, 5, 8].

2.5. Limitaciones y riesgos

Entre las posibles fuentes de riesgo se consideran la disponibilidad limitada de datos anotados, la heterogeneidad biológica y técnica de las muestras y la sensibilidad del desempeño a la selección de hiperparámetros. Estas circunstancias pueden inducir estimaciones optimistas si no se controlan adecuadamente. Para mitigarlas, se adoptan protocolos de validación estadísticamente sólidos—en particular, validación cruzada anidada y análisis de estabilidad—y se documentan todas las decisiones de preprocesamiento y modelado mediante reportes ejecutables que faciliten auditoría y réplica independiente [11, 12]. La generalización fuera del dominio inmediato de adquisición se reconoce como un objetivo de trabajos posteriores que requerirá cohortes externas y estudios multicentro [5, 8].

2.6. Hipótesis y productos esperados

La hipótesis de trabajo sostiene que un flujo de procesamiento basado en descriptores de textura, morfología y frecuencia, combinado con clasificadores clásicos entrenados y evaluados bajo validación cruzada anidada, puede discriminar con fiabilidad hologramas DLHM de eritrocitos sanos y falciformes sin necesidad de reconstrucción, alcanzando desempeño competitivo con la literatura y con incertidumbre cuantificada [4, 5, 8, 11, 12]. Como productos se esperan un conjunto de *scripts* y modelos serializados listos para reproducción, bitácoras y reportes automatizados de métricas, y una guía operativa para su evaluación técnica posterior, en concordancia con las directrices institucionales de propiedad intelectual [16].

Capítulo 3

Marco teórico

Este capítulo desarrolla el sustento científico que articula la óptica holográfica, la representación matemática de los hologramas y los modelos de aprendizaje automático empleados para su clasificación. Se pretende consolidar un hilo conductor que vaya desde la física de la formación del interferograma hasta los mecanismos de decisión, calibración y gobernanza que permiten utilizar el sistema en contextos clínicos reales.

3.1. Formación del holograma y modelos de propagación

En DLHM el sensor registra en una sola exposición la intensidad resultante de superponer una onda de referencia U_{ref} con la onda objeto U_{obj} modulada por la muestra. Asumiendo campo escalar, coherencia temporal suficiente y régimen paraxial, la intensidad en el plano del sensor (x, y) es

$$I(x, y) = |U_{\text{ref}}(x, y) + U_{\text{obj}}(x, y)|^2 = |U_{\text{ref}}|^2 + |U_{\text{obj}}|^2 + 2 \Re\{U_{\text{ref}} U_{\text{obj}}^*\}, \quad (3.1)$$

de donde se reconoce que el término de interferencia transporta la información de fase y amplitud de la muestra [4]. En configuraciones de iluminación cuasi-plana, puede escribirse $U_{\text{ref}}(x, y) = A_{\text{ref}} e^{j\phi_{\text{ref}}}$ con A_{ref} aproximadamente constante sobre el sensor; esta aproximación linealiza el contraste del interferograma y estabiliza el cociente señal-ruido (SNR) frente a fluctuaciones de U_{obj} [4, 8].

La propagación desde el plano del objeto $z = 0$ al plano del sensor z se modela, bajo hipótesis paraxial y banda limitada, por el integral de Fresnel:

$$U(x, y, z) = \frac{e^{jkz}}{j\lambda z} \iint U(x', y', 0) \exp\left\{\frac{jk}{2z}[(x - x')^2 + (y - y')^2]\right\} dx' dy', \quad (3.2)$$

con $k = 2\pi/\lambda$ [6]. Cuando la distancia muestra-sensor es pequeña respecto al tamaño del sensor o se requiere exactitud fuera de la paraxialidad, resulta más apropiada la formulación de Rayleigh-Sommerfeld,

$$U(x, y, z) = \frac{1}{j\lambda} \iint U(x', y', 0) \frac{e^{jkr}}{r} \cos \theta \, dx' dy', \quad (3.3)$$

donde $r = \sqrt{(x - x')^2 + (y - y')^2 + z^2}$ y θ es el ángulo entre la normal al plano y el vector unión; el factor $\exp(jkr)/r$ preserva la curvatura del frente de onda y permite cuantificar la sensibilidad del patrón a desalineaciones [6]. En prácticas computacionales, ambas expresiones se implementan mediante sus versiones convolutivas y FFT, cuidando la periodicidad implícita y el *zero-padding* para evitar aliasing circular [6, 8].

El muestreo discreto impone vínculos estrictos entre el *pitch* del sensor Δ , la distancia z y el contenido angular del objeto. Si I se adquiere en una retícula $\Delta \times \Delta$, la frecuencia espacial observable está acotada por $f_{\text{máx}} = 1/(2\Delta)$. Para un objeto con máximos ángulos de difracción $\theta_{\text{máx}}$, la condición de Nyquist puede expresarse como

$$\frac{\lambda z}{\Delta^2} \gtrsim \pi^{-1} \iff z \gtrsim \frac{\pi \Delta^2}{\lambda}, \quad (3.4)$$

relación que fija cotas inferiores para z y evita que los órdenes de difracción se plieguen en el espectro del sensor [6]. La coherencia espacial se controla con diafragmas o guías de onda que introducen una función pupilar $P(u, v)$ en el dominio de frecuencias; en presencia de esta apodización, el campo propagado se expresa como

$$U(x, y, z) = \mathcal{F}^{-1}\{\mathcal{F}\{U(x, y, 0)\} H_z(u, v) P(u, v)\}, \quad (3.5)$$

donde $H_z(u, v)$ es el filtro de transferencia de Fresnel en frecuencia. Esta forma pone de manifiesto cómo la óptica del sistema recorta componentes de alta frecuencia y justifica la normalización geométrica y radiométrica previa a la extracción de descriptores [6, 8].

En configuraciones en línea (*on-axis*) la medida (3.1) contiene los términos $|U_{\text{ref}}|^2$ y $|U_{\text{obj}}|^2$ además del cruzado; la separación espectral de estos términos se logra explotando la curvatura de U_{ref} o con esquemas ligeramente *off-axis* que desplazan el lóbulo de interferencia, facilitando el aislamiento del término portador sin reconstrucción explícita del campo complejo [8]. La cuantificación del SNR del interferograma puede aproximarse como

$$\text{SNR} \approx \frac{2A_{\text{ref}}A_{\text{obj}}}{\sqrt{\sigma_{\text{shot}}^2 + \sigma_{\text{lectura}}^2 + \sigma_{\text{cuant}}^2}}, \quad (3.6)$$

con varianzas asociadas a ruido de conteo, lectura y cuantización; esto motiva la elección de exposiciones que mantengan A_{ref} dominante pero sin saturación, optimizando el contraste de franjas [4, 8].

La estabilidad geométrica también es crítica: desalineaciones por *tilt* o curvatura de frente se modelan como fases cuadráticas $\exp\{j\pi(ax^2 + by^2 + cxy)\}$. Tales aberraciones se compensan estimando y retirando el plano/curvatura de fase en el dominio frecuencial, operación que mejora la estacionariedad de las franjas y reduce fugas espectrales [8]. En suma, las ecuaciones (3.2)–(3.5) y las restricciones de muestreo (3.4) delimitan la región de operación segura del montaje DLHM, aportando una base física para los pasos de control de calidad y normalización empleados aguas abajo [6, 4, 8].

3.2. Representación matemática de texturas holográficas

Un holograma en intensidad $I : \Omega \subset \mathbb{Z}^2 \rightarrow \mathbb{R}_+$ codifica modulaciones mixtas de amplitud y fase cuyo patrón de franjas exhibe periodicidades, anisotropías y discontinuidades finas. La estrategia adoptada es construir un vector de características $\mathbf{x} \in \mathbb{R}^d$ que preserve esa física mediante descriptores locales y globales en dominios espacial, frecuencial y multiescala, evitando la reconstrucción del campo complejo. El flujo se resume en la Fig. 3.1 y se fundamenta en operadores con propiedades de invariancia y estabilidad bien caracterizadas [4, 8, 5].

Preprocesamiento radiométrico y normalización geométrica. Sea $\tilde{I}$ la versión corregida de *flat-field* y *dark-frame* de I ; se normaliza a rango

Transformaciones clave para la caracterización holográfica




Figura 3.1: Transformaciones clave aplicadas sobre un holograma falciforme: interferograma original, magnitud logarítmica de la transformada de Fourier, mapa uniforme de LBP, respuesta de un filtro de Gabor, energía combinada de coeficientes wavelet y matriz de coocurrencia GLCM normalizada.

unitario con

$$I_n(x, y) = \frac{\tilde{I}(x, y) - P_1\{\tilde{I}\}}{P_{99}\{\tilde{I}\} - P_1\{\tilde{I}\}},$$

donde $P_q\{\cdot\}$ denota el percentil q . Para estabilizar el contraste local se emplea realce adaptativo tipo CLAHE sobre I_n , lo que atenúa saturaciones y conserva bordes finos relevantes para la textura [4, 5]. Todas las operaciones se realizan tras redimensionar a 512×512 para fijar una malla de muestreo común y respetar las restricciones espectrales discutidas en la Sección previa [6].

Patrones locales (LBP). La microtextura alrededor de (x_c, y_c) se codifica con el operador

$$\text{LBP}_{P,R}(x_c, y_c) = \sum_{p=0}^{P-1} \mathbf{1}[g_p - g_c \geq 0] 2^p, \quad (3.7)$$

donde $g_c = I_n(x_c, y_c)$ y $\{g_p\}_{p=0}^{P-1}$ son intensidades en una circunferencia de radio R muestreada con interpolación bilineal. La estadística usada es el histograma normalizado $h \in \Delta^{2^P-1}$. Para reducir la varianza y obtener invariancia a rotación, se adopta la versión uniforme $u2$ y la variante LBP_{ri} basada en rotaciones cíclicas que minimizan el patrón binario [17].

Coocurrencias de niveles de gris (GLCM). Sea Q la cuantización escalar de I_n a L niveles. Para un desplazamiento $\Delta = (\Delta_x, \Delta_y)$ y un ángulo θ , la matriz de coocurrencias $P_{\Delta, \theta} \in [0, 1]^{L \times L}$ se define por

$$P_{\Delta, \theta}(i, j) = \frac{1}{N} \sum_{(x, y) \in \Omega} \mathbf{1}[Q(x, y) = i] \mathbf{1}[Q(x + \Delta_x, y + \Delta_y) = j], \quad (3.8)$$

con normalización $\sum_{i, j} P(i, j) = 1$ [18]. A partir de (3.8) se obtienen medidas interpretables: contraste $C = \sum_{i, j} (i - j)^2 P(i, j)$, homogeneidad $H = \sum_{i, j} P(i, j) / [1 + (i - j)^2]$, energía $E = \sum_{i, j} P(i, j)^2$ y correlación $\rho = \sum_{i, j} i j P(i, j) - \mu_x \mu_y$, con medias μ_x, μ_y . Promediar sobre $\theta \in \{0, \pi/4, \pi/2, 3\pi/4\}$ atenúa efectos direccionales espurios y captura la granularidad interferométrica [18].

Contenido frecuencial y anisotropía angular. Sea $\hat{I} = \mathcal{F}\{I_n\}$ la transformada de Fourier bidimensional. La densidad espectral de potencia $S(u, v) = |\hat{I}(u, v)|^2$ permite definir un perfil radial mediante anillos concéntricos $\mathcal{A}_k = \{(u, v) : r_k \leq \sqrt{u^2 + v^2} < r_{k+1}\}$:

$$E_k = \iint_{\mathcal{A}_k} S(u, v) du dv, \quad (3.9)$$

que resume el reparto de energía por número de franjas; hologramas con patrones más regulares tienden a concentrar energía en bajas frecuencias [4, 8]. La anisotropía se cuantifica con el segundo momento angular del espectro,

$$\mathcal{A} = \frac{\lambda_{\text{máx}} - \lambda_{\text{mín}}}{\lambda_{\text{máx}} + \lambda_{\text{mín}}}, \quad \{\lambda_{\text{mín}}, \lambda_{\text{máx}}\} = \text{autovalores de } \mathbf{M} = \iint \begin{bmatrix} u^2 & uv \\ uv & v^2 \end{bmatrix} \frac{S(u, v)}{\iint S} du dv, \quad (3.10)$$

donde $\mathcal{A} \in [0, 1)$ crece con la direccionalidad de las franjas [4].




Figura 3.2: Comparativa de descriptores entre un holograma sano (fila superior) y uno falciforme (fila inferior). Cada columna exhibe el holograma original, el histograma LBP, la energía espectral por anillos de Fourier y la energía acumulada de los coeficientes wavelet.

Filtros de Gabor. La respuesta orientada se modela con bancos $\{g_{\theta,\lambda}\}$ definidos por

$$g_{\theta,\lambda}(x, y) = \exp\left(-\frac{x'^2 + \gamma^2 y'^2}{2\sigma^2}\right) \cos\left(\frac{2\pi x'}{\lambda}\right), \quad \begin{cases} x' = x \cos \theta + y \sin \theta, \\ y' = -x \sin \theta + y \cos \theta, \end{cases} \quad (3.11)$$

y características basadas en momentos de $|I_n * g_{\theta,\lambda}|$ (media, varianza y curtosis por par (θ, λ)) [10].

Energía multiescala por wavelets. La transformada wavelet discreta separa I_n en coeficientes de aproximación $A^{(\ell)}$ y detalles $D_h^{(\ell)}, D_v^{(\ell)}, D_d^{(\ell)}$ por nivel ℓ . La energía por escala se define como

$$W^{(\ell)} = \frac{1}{|D^{(\ell)}|} \sum_{(x,y)} \left[D_h^{(\ell)}(x, y)^2 + D_v^{(\ell)}(x, y)^2 + D_d^{(\ell)}(x, y)^2 \right], \quad (3.12)$$

y captura irregularidades finas y bordes a distintas resoluciones [10].

Morfometría en máscara binaria. Para complementar la textura se obtiene una máscara M por umbralización adaptativa y limpieza morfológica. A partir de M se calculan área $A = \sum M$, perímetro P y casco convexo A_{conv} . La circularidad $C = 4\pi A/P^2$, la solidez $S = A/A_{\text{conv}}$ y la excentricidad $e = \sqrt{1 - \lambda_2/\lambda_1}$ (con $\lambda_1 \geq \lambda_2$ autovalores de la matriz de inercia) cuantifican deformaciones geométricas asociadas a falcización [10]. Se añaden momentos de intensidad a primer–cuarto orden y entropía de Shannon sobre I_n para capturar dispersión radiométrica [19].

Estandarización y selección. Todas las características se estandarizan con estimadores robustos (mediana y MAD) y se filtran con pruebas de varianza casi nula; se aplica selección supervisada SelectKBest con estadísticos monotónicos y validación anidada para evitar fuga de información [12]. Este pipeline produce vectores $\mathbf{x}$ estables frente a variaciones suaves de iluminación, traslación y rotación, preservando señales físicas relevantes del interferograma [4, 8, 5].

3.3. Modelación estadística de los clasificadores

La tarea de discriminación entre hologramas de eritrocitos sanos y falciformes se formula como un problema de inferencia probabilística en el que, dado un vector de características $\mathbf{x} \in \mathbb{R}^d$, se desea estimar $p(y = 1 \mid \mathbf{x})$ con $y \in \{0, 1\}$. El aprendizaje se plantea mediante la minimización del riesgo empírico regularizado, lo que implica resolver

$$\hat{f} \in \arg \min_{f \in \mathcal{H}} \frac{1}{n} \sum_{j=1}^n \ell(y_j, f(\mathbf{x}_j)) + \Omega(f), \quad (3.13)$$

con una pérdida ℓ apropiada para clasificación y un término Ω que controla la complejidad para favorecer generalización, especialmente relevante en el régimen de pocos datos y alta dimensionalidad característico de DLHM [12, 11]. La estimación de hiperparámetros y la selección de transformaciones se realiza dentro de un esquema de validación cruzada anidada con particiones estratificadas, de forma que cualquier paso de selección o reescalado quede confinado al pliegue de entrenamiento y se evite fuga de información [12, 11].

La regresión logística penalizada modela la probabilidad posterior mediante un mapeo sigmoideal de una combinación lineal de características, $P(y = 1 | \mathbf{x}) = \sigma(\beta_0 + \sum_{i=1}^d \beta_i x_i)$ con $\sigma(z) = 1/(1 + e^{-z})$. La estimación se formula como una maximización de verosimilitud con penalización ℓ_1 , ℓ_2 o combinada (elastic net), tal como

$$\mathcal{L}(\boldsymbol{\beta}) = - \sum_{j=1}^n [y_j \log \sigma(z_j) + (1 - y_j) \log(1 - \sigma(z_j))] + \lambda \left(\alpha \|\boldsymbol{\beta}\|_1 + \frac{1 - \alpha}{2} \|\boldsymbol{\beta}\|_2^2 \right), \quad (3.14)$$

donde $\lambda > 0$ controla la magnitud de la regularización y $\alpha \in [0, 1]$ pondera la esparsidad frente a la estabilidad numérica [20]. Esta formulación ofrece coeficientes interpretables en términos de log-odds y, con ponderaciones por clase cuando existe desbalance, permite ajustar sensibilidad y especificidad al criterio clínico.

Cuando la separación lineal en el espacio original no es adecuada, la máquina de soporte vectorial con núcleo gaussiano proyecta implícitamente las muestras a un espacio de Hilbert de dimensión infinita en el que la maximización del margen es efectiva. El problema dual

$$\max_{\boldsymbol{\alpha}} \sum_{j=1}^n \alpha_j - \frac{1}{2} \sum_{j,k=1}^n \alpha_j \alpha_k y_j y_k K(\mathbf{x}_j, \mathbf{x}_k), \quad \text{sujeto a } 0 \leq \alpha_j \leq C, \sum_j \alpha_j y_j = 0, \quad (3.15)$$

con $K(\mathbf{x}, \mathbf{x}') = \exp(-\gamma \|\mathbf{x} - \mathbf{x}'\|^2)$, produce una función de decisión $g(\mathbf{x}) = \text{sign}(\sum_{j \in SV} \alpha_j y_j K(\mathbf{x}, \mathbf{x}_j) + b)$ que controla el compromiso entre error de entrenamiento y complejidad mediante C y γ [20]. Para disponer de probabilidades calibradas, el puntaje de margen se transforma a escala probabilística con un ajuste logístico o isotónico en un conjunto de calibración independiente del ajuste del hiperparámetro [20].

Los modelos basados en árboles exploran interacciones no lineales y umbrales en las variables sin requerir supuestos de linealidad. Un bosque aleatorio entrena múltiples árboles sobre remuestreos de las observaciones y subespacios aleatorios de características, y promedia sus salidas probabilísticas para reducir la varianza debida a la inestabilidad de cada árbol individual. La impureza (Gini o entropía) guía las particiones axis-aligned, y la agregación final hereda robustez ante *outliers* y escalas heterogéneas [20]. En contraste, el gradiente por potenciación construye un modelo aditivo $F_m(\mathbf{x}) = F_{m-1}(\mathbf{x}) + \nu h_m(\mathbf{x})$ donde h_m es un árbol poco profundo ajustado al gradiente negativo de la

pérdida logística; la tasa de aprendizaje ν , el número de iteraciones y la profundidad controlan el equilibrio sesgo–varianza y actúan como regularización explícita en el espacio de funciones [21]. La combinación de ambos enfoques aporta capacidad de modelado no lineal complementaria a los clasificadores lineales.

Con el fin de estabilizar el desempeño en el régimen de pocos datos y reducir la varianza de estimación, las salidas probabilísticas de modelos heterogéneos se combinan en una mezcla convexa

$$p_{\text{ens}}(y = 1 \mid \mathbf{x}) = \sum_k w_k p_k(y = 1 \mid \mathbf{x}), \quad w_k \geq 0, \quad \sum_k w_k = 1, \quad (3.16)$$

donde los pesos w_k se determinan en un pliegue de calibración para minimizar una métrica propia de probabilidad, como la pérdida de Brier, preservando la interpretabilidad agregada y amortiguando errores idiosincráticos de cada base [20]. La decisión final $\hat{y} = \mathbf{1}[p_{\text{ens}} \geq \tau]$ se ajusta a costes clínicos mediante la elección de un umbral τ que optimiza, por ejemplo, el índice de Youden o que satisface una cota mínima de sensibilidad cuando el falso negativo es crítico.

La evaluación rigurosa de generalización se fundamenta en métricas umbral-independientes y umbral-dependientes. Se reporta el área bajo la curva ROC y, en presencia de desbalance, la curva de precisión–recobrado, junto con precisión balanceada, sensibilidad y especificidad puntuales. La incertidumbre de estas estimaciones se cuantifica con repetición de la validación cruzada estratificada y con intervalos de confianza por *bootstrap*, siempre respetando la anidación: toda transformación de características, estandarización robusta y selección supervisada se ejecuta dentro de cada pliegue de entrenamiento para evitar sesgos optimistas [11, 12]. La calibración probabilística se verifica mediante diagramas de confiabilidad y pérdida de Brier, aplicando, cuando procede, calibración isotónica o Platt sobre un conjunto de calibración separado del ajuste de hiperparámetros [20].

En conjunto, la articulación de un clasificador lineal penalizado, un margin-based kernel method y ensambles de árboles, todos integrados bajo una validación anidada y una capa explícita de calibración, proporciona un andamiaje estadístico coherente con las restricciones del problema: alta dimensionalidad relativa al tamaño muestral, potenciales colinealidades entre descriptores físicos y necesidad de interpretar decisiones a nivel de característica. Este marco

da soporte a las afirmaciones de desempeño con garantías estadísticas explícitas y mantiene la trazabilidad necesaria para auditoría y gobernanza del modelo en contextos clínicos [12, 11, 20, 21].

3.4. Detección de anomalías, calibración e incertidumbre

El funcionamiento seguro en un entorno clínico requiere distinguir entre entradas pertenecientes al dominio de entrenamiento y observaciones que se desvían de él, así como cuantificar y comunicar la incertidumbre asociada a cada decisión. La detección de anomalías se aborda mediante la distancia de Mahalanobis definida sobre el espacio de características estandarizadas. Sea $\mathbf{x} \in \mathbb{R}^d$ el vector de características y sea $(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ la media y la covarianza robustas estimadas en el conjunto de entrenamiento; la estadística

$$D_M^2(\mathbf{x}) = (\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}) \quad (3.17)$$

resume la discrepancia cuadrática con respecto a la distribución empírica del dominio [14]. Para atenuar la influencia de atípicos y colinealidades en $\boldsymbol{\Sigma}$, la estimación se realiza con procedimientos robustos basados en el *Minimum Covariance Determinant* (MCD), que maximizan la verosimilitud sobre subconjuntos de alta densidad y ofrecen consistencia bajo contaminación moderada [15]. Bajo supuestos aproximadamente gaussianos en el espacio transformado, D_M^2 se distribuye como χ_d^2 , lo que permite fijar un umbral $\tau_\alpha = \chi_{d,1-\alpha}^2$ para un nivel de significancia α y derivar valores p mediante $p(\mathbf{x}) = 1 - F_{\chi_d^2}(D_M^2(\mathbf{x}))$. La descomposición por coordenadas

$$c_i(\mathbf{x}) = (e_i^\top \boldsymbol{\Sigma}^{-1/2} (\mathbf{x} - \boldsymbol{\mu}))^2, \quad i = 1, \dots, d, \quad (3.18)$$

con $\{e_i\}$ base canónica, ofrece una lectura de contribuciones que facilita interpretar qué componentes del descriptor impulsan la alerta y, por tanto, sustenta la revisión clínica de casos fuera de dominio [15]. En la operación prospectiva, el umbral τ_α se valida por *bootstrap* estratificado para mantener tasas de falsa alarma controladas en tamaños muestrales finitos y para documentar la estabilidad del detector a variaciones de calibración.

La incertidumbre asociada a la clasificación se cuantifica en dos niveles complementarios. En primer lugar, la calibración probabilística verifica la concordancia entre probabilidades pronosticadas y frecuencias observadas. Dada

una función $p(\mathbf{x}) \in [0, 1]$, la pérdida de Brier

$$\text{BS} = \frac{1}{n} \sum_{j=1}^n (p(\mathbf{x}_j) - y_j)^2 \quad (3.19)$$

proporciona una medida propia, y las curvas de confiabilidad contrastan visualmente la relación entre probabilidad estimada y tasa empírica de positivos en intervalos de puntuación. Cuando se detecta descalibración, se emplea ajuste isotónico o mapeo logístico sobre un conjunto de calibración separado del ajuste de hiperparámetros, manteniendo la independencia entre entrenamiento, calibración y prueba [20]. En segundo lugar, la predicción conforme introduce conjuntos de salida con garantía de cobertura finita-muestral bajo intercambiabilidad. Sea $\alpha(\mathbf{x}, y)$ una medida de no conformidad calculada a partir de las puntuaciones del modelo; en el esquema *split conformal*, se calcula el cuantil $q_{1-\epsilon}$ de las no conformidades en un conjunto de calibración y se define el conjunto de predicción

$$\Gamma_\epsilon(\mathbf{x}) = \{y \in \{0, 1\} : \alpha(\mathbf{x}, y) \leq q_{1-\epsilon}\}, \quad (3.20)$$

que garantiza cobertura marginal $1 - \epsilon$ sin supuestos paramétricos [13]. En clasificación binaria, la elección $\alpha(\mathbf{x}, 1) = 1 - p(\mathbf{x})$ y $\alpha(\mathbf{x}, 0) = p(\mathbf{x})$ produce conjuntos $\Gamma_\epsilon(\mathbf{x})$ de tamaño uno (decisión puntual) o dos (abstención informada), lo que resulta apropiado cuando los costos clínicos penalizan con severidad los falsos negativos. La combinación de calibración probabilística y predicción conforme habilita tanto la toma de decisiones costo-sensitivas mediante umbrales explícitos como la emisión de alertas de baja confianza documentadas y auditables [13, 20].

3.5. Integración interdisciplinaria, ética y líneas de investigación

El desempeño técnico del sistema depende de un acoplamiento explícito entre la modelación óptica, el diseño estadístico y la práctica clínica. La documentación de parámetros ópticos y condiciones de adquisición—distancia muestra-sensor, longitud de onda, paso del pixel y protocolos de control de iluminación—asegura la reproducibilidad de los interferogramas y sustenta las hipótesis de propagación y muestreo empleadas en el preprocesamiento.

La construcción del vector de características y la selección de clasificadores se apoya en validación cruzada anidada y en procedimientos de calibración probabilística, con registro de todas las decisiones de ingeniería y de sus efectos sobre las métricas para mantener trazabilidad y permitir auditoría independiente [12, 11, 20]. La verificación clínica incorpora la revisión de casos límite, el estudio de errores por subgrupos y la evaluación del impacto de umbrales costo-sensitivos en escenarios de cribado, privilegiando configuraciones con sensibilidad mínima garantizada cuando el falso negativo comporta riesgo sanitario significativo.

El cumplimiento normativo y la gobernanza del modelo se alinean con el reglamento de propiedad intelectual de la Universidad EAFIT, que exige preservar la trazabilidad de datos y modelos, delimitar claramente los derechos de uso y asegurar supervisión humana en decisiones asistenciales [16]. En paralelo, las recomendaciones contemporáneas sobre inteligencia artificial responsable enfatizan la transparencia metodológica, la explicabilidad de las decisiones y los mecanismos de detección de entradas fuera del dominio, todos ellos incorporados mediante reportes reproducibles, análisis de contribuciones en la distancia de Mahalanobis y predicción conforme con cobertura controlada [13]. Esta arquitectura sugiere líneas de investigación continuas: la caracterización óptica detallada del montaje facilitaría la generación de datos sintéticos controlados para estudios de sensibilidad; los modelos híbridos que integren descriptores físicos con representaciones aprendidas explicables podrían mejorar la sensibilidad a patrones sutiles manteniendo interpretabilidad; la validación multicéntrica permitiría cuantificar robustez ante cambios de dominio y sostener generalización externa en poblaciones diversas.

La consolidación de estos componentes articula un marco que vincula la física de la formación del holograma con la representación estadística y la inferencia probabilística, y que incorpora salvaguardas de detección de dominio y comunicación de incertidumbre. Este marco no sólo proporciona garantías cuantitativas sobre el desempeño esperado, sino que también define prácticas de documentación, supervisión humana y auditoría que son coherentes con la integración del sistema en flujos de trabajo clínicos reales [16, 13].

Capítulo 4

Metodología

La metodología se concibe para sostener reproducibilidad, interpretabilidad y validez estadística en un escenario de muestra limitada, articulando la física de adquisición con un andamiaje de inferencia probabilística y de control de incertidumbre. El flujo integra gobernanza y curaduría de datos, normalización geométrica–radiométrica con justificación óptica, extracción de descriptores con fundamento físico–estadístico, ajuste de clasificadores lineales y no lineales con regularización explícita, validación cruzada anidada y verificación de calibración, además de un subsistema de detección de entradas fuera de dominio y un régimen de documentación que preserve la trazabilidad de cada decisión técnica y de cada artefacto generado [12, 11, 20, 16].

4.1. Datos, gobernanza y normalización

El estudio emplea 304 hologramas rotulados capturados con un único montaje DLHM y almacenados en formato PNG de 8 bits, con resolución máxima de 4640×3506 píxeles. La clase saludable comprende 151 interferogramas de eritrocitos sin rasgos patológicos y la clase patológica 153 interferogramas correspondientes a anemia falciforme; a efectos de evaluación de robustez fuera de dominio se dispone, en repositorio separado, de 30 hologramas de organismos no sanguíneos—esporas de *Aspergillus*, diatomeas y partículas de gramíneas—que no participan del ajuste del clasificador. La gobernanza de datos asegura integridad mediante sumas criptográficas y verificación de cabeceras, mantiene un registro de control de archivos y preserva únicamente

metadatos técnicos mínimos (fecha y operador) necesarios para trazabilidad y auditoría, eliminando identificadores sensibles conforme al reglamento de propiedad intelectual de la Universidad EAFIT [16]. La organización del repositorio impone versionado de directorios y artefactos derivados, de modo que cualquier figura o métrica reportada pueda rastrearse al estado específico del conjunto y al commit de código que la produjo, alineando prácticas con recomendaciones contemporáneas de ciencia reproducible [12].

La normalización se diseña como un proceso determinista que preserva relaciones espectrales y evita ambigüedades de muestreo. Cada holograma I se corrige radiométricamente (cuando hay marcos *dark/flat*) y se lleva a rango unitario mediante percentiles robustos P_1 – P_{99} , estabilizando el contraste frente a atípicos. El tamaño objetivo de 512×512 píxeles se obtiene por recorte central cuando la resolución lo permite para no diluir contenidos de alta frecuencia y por interpolación bilineal en caso de resoluciones inferiores, fijando una malla de muestreo coherente con las restricciones de Nyquist tratadas en el marco óptico [6]. Se aplica CLAHE para realce de contraste local y un filtrado de mediana suave para atenuar ruido impulsivo sin erosionar bordes interferométricos [19]. Las desalineaciones por inclinación o curvatura del frente se modelan como fases cuadráticas y se compensan en el dominio frecuencial retirando términos de baja orden, lo que mejora la estacionariedad de las franjas y reduce fugas espectrales en operadores espectrales posteriores [4, 8]. Cada corrida escribe una bitácora con parámetros aplicados, hashes de entrada y salida, estadísticas radiométricas pre y post normalización, y marcas temporales; esta documentación permite reproducir fielmente el estado del sistema y detectar divergencias al incorporar nuevos lotes de datos [12, 11].

4.2. Extracción de descriptores físicos y estadísticos

La representación de cada holograma normalizado I_n se construye sin reconstruir el campo complejo, preservando la física de la formación del interferograma mediante descriptores complementarios en dominios espacial, frecuencial y multiescala. La microtextura se codifica con LBP $_{P,R}$ en variantes uniformes e invariantes a rotación, cuyo histograma normalizado conserva diferencias locales de intensidad con estabilidad frente a cambios suaves de

iluminación y a pequeñas deformaciones geométricas [17]. La textura de segundo orden se resume con matrices de coocurrencia $P_{\Delta,\theta}$ y con métricas derivadas—contraste, homogeneidad, energía, correlación—promediadas sobre orientaciones canónicas para amortiguar direccionalidades espurias, lo que captura la granularidad interferométrica y la repetitividad de las franjas [18]. En el dominio de Fourier se calcula la energía por anillos concéntricos y un índice de anisotropía basado en el segundo momento angular del espectro, sensibles a la concentración de energía en bajas frecuencias y a la direccionalidad del patrón, respectivamente [4, 8]. La respuesta orientada se enriquece con bancos de Gabor parametrizados por orientación y longitud de onda, cuyos momentos sobre $|I_n * g_{\theta,\lambda}|$ discriminan periodicidades y oblicuidades ligadas a deformaciones típicas [10]. La multiescala se incorpora mediante energías de detalles wavelet $W^{(\ell)}$ en familias Daubechies de soporte compacto, proporcionando sensibilidad a irregularidades finas en varias resoluciones [10]. Para completar con morfometría, una máscara binaria obtenida por umbralización adaptativa y limpieza morfológica habilita métricas geométricas—área, perímetro, circularidad, solidez y excentricidad—junto con momentos globales de intensidad y entropía de Shannon, de utilidad cuando cambios de fase inducen contornos efectivos persistentes en intensidad [19, 10].

Todos los descriptores se estandarizan con mediana y MAD para reducir sensibilidad a colas pesadas y se filtran por varianza casi nula antes del ajuste. La reducción supervisada se efectúa con SelectKBest dentro de los pliegues de entrenamiento, utilizando estadísticos acordes a la escala de cada característica; esta decisión limita dimensionalidad efectiva, controla colinealidades residuales y evita fuga de información al mantener los pasos de selección estrictamente confinados a los conjuntos de entrenamiento en el marco de validación anidada [12, 11]. La configuración de radios, distancias y orientaciones se fijó tras exploración documentada que comparó alternativas con base en separabilidad y estabilidad entre ejecuciones, manteniendo un registro de parámetros que facilita auditoría y reproducción. Los vectores $\mathbf{x}$ y metadatos asociados se serializan con huellas criptográficas y referencias a la versión de código, asegurando consistencia entre estado de datos, configuración y resultados.

4.3. Modelado, validación y calibración

El aprendizaje se formula como minimización de riesgo empírico regularizado, con un portafolio de clasificadores que aportan sesgos inductivos complementarios. La regresión logística penalizada modela $p(y = 1 \mid \mathbf{x})$ mediante un mapeo sigmoideal de combinación lineal de descriptores y emplea penalizaciones L_1 , L_2 o elásticas para promover parsimonia y estabilidad numérica; los coeficientes estimados se interpretan en términos de log-odds y contribuyen a la trazabilidad clínica [20]. La máquina de soporte vectorial con núcleo RBF despliega una frontera no lineal mediante proyección implícita a un RKHS, controlando el equilibrio entre error empírico y complejidad a través de C y γ ; las puntuaciones de margen se transforman luego a probabilidades mediante calibración posterior independiente del ajuste de hiperparámetros [20]. Los modelos basados en árboles abordan interacciones y umbrales sin supuestos de linealidad: el bosque aleatorio reduce varianza por agregación sobre remuestreos y subespacios de características, mientras que la potenciación de gradiente construye una aproximación aditiva con árboles poco profundos que optimiza la pérdida logística con regularización funcional implícita mediante tasa de aprendizaje y profundidad [21]. Estas tres familias capturan de forma conjunta relaciones lineales interpretables, separaciones de margen en espacios no lineales y particiones jerárquicas con interacción de variables.

Las salidas probabilísticas de los modelos se integran en una mezcla convexa $p_{\text{ens}}(\mathbf{x}) = \sum_k w_k p_k(\mathbf{x})$, con pesos aprendidos en un pliegue de calibración dedicado para minimizar la pérdida de Brier; esta combinación atenúa la varianza de estimación, rescata contribuciones complementarias y evita que un único inductivo domine en regiones de escasez de datos [20]. La selección de hiperparámetros— λ, α en logística; C, γ en SVM; número de árboles, profundidad y tasa de aprendizaje en ensambles—se realiza mediante búsqueda aleatoria acotada dentro de una validación cruzada interna estratificada; el número k de características retenidas se optimiza de forma conjunta. La capa externa de evaluación reserva un subconjunto de prueba estratificado y reporta métricas umbral-independientes (ROC-AUC y, cuando procede, PR-AUC) y umbral-dependientes (precisión balanceada, sensibilidad y especificidad), con intervalos de confianza al 95 % obtenidos por *bootstrap* estratificado de alta repetición; la estricta anidación garantiza que toda transformación y selección se ajuste exclusivamente con información del entrenamiento [11, 12]. La calibración probabilística se verifica con pérdida de Brier y diagramas de

confiabilidad; cuando se detecta descalibración se aplica ajuste isotónico o mapeo logístico sobre un conjunto de calibración distinto del empleado para la búsqueda de hiperparámetros, manteniendo independencia entre etapas [20]. La decisión clínica se establece fijando un umbral τ costo-sensible que garantice sensibilidad mínima cuando el falso negativo tiene costo elevado, o bien a través del índice de Youden cuando se busca equilibrio, documentando la incidencia de τ en los intercambios sensibilidad-especificidad.

4.4. Incertidumbre, anomalías y reproducibilidad operativa

La comunicación de incertidumbre se articula con predicción conforme en esquema *split*, utilizando como medida de no conformidad funciones de las probabilidades calibradas del ensamble. El cuantil $q_{1-\epsilon}$ estimado en el conjunto de calibración define conjuntos de predicción $\Gamma_\epsilon(\mathbf{x})$ con garantía de cobertura marginal $1 - \epsilon$ bajo intercambiabilidad, habilitando abstenciones informadas cuando la evidencia es insuficiente y alineando el sistema con prácticas clínicas de revisión prioritaria [13]. La detección de entradas fuera de dominio se implementa con distancia de Mahalanobis $D_M^2 = (\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu})$ calculada sobre el subespacio de características seleccionadas; la media y la covarianza se estiman mediante procedimientos robustos tipo *Minimum Covariance Determinant* para resistir contaminación y colinealidades, y los umbrales τ_α se fijan frente a la referencia χ_d^2 con validación por *bootstrap* [14, 15]. La descomposición por coordenadas de D_M^2 aporta contribuciones específicas de cada descriptor, lo que facilita la interpretación de alertas y el diálogo con especialistas. El conjunto externo de 30 hologramas no sanguíneos se reserva para valorar tasas de verdadera y falsa alarma del detector y para verificar estabilidad de umbrales frente a variaciones de dominio.

La reproducibilidad operativa descansa en una automatización integral del flujo a través de una interfaz de línea de comandos que parametriza rutas de datos, configuración de extracción, selección de características, esquemas de validación y calibración. Cada ejecución genera artefactos versionados—vectores de características con metadatos, modelos y calibradores serializados—además de reportes con curvas ROC/PR, matrices de confusión, diagramas de confiabilidad y análisis de estabilidad de selección, todos con huellas criptográficas y referencias explícitas a la versión del código [12, 16].

La coordinación periódica con el equipo clínico permite revisar casos residuales, recalibrar umbrales costo-sensitivos y ajustar el balance entre sensibilidad y especificidad; la fase piloto prevista se ejecutará en paralelo con el flujo diagnóstico estándar para recolectar evidencia prospectiva, actualizar calibraciones y analizar desempeño por subgrupos antes de evaluar cualquier despliegue asistencial [13]. En este marco, la modularidad del código habilita la incorporación futura de descriptores adicionales o de representaciones aprendidas explicables sin alterar la interfaz pública del sistema, preservando el mismo régimen de validación y de control de calibración [4, 8, 5, 20]. s

Capítulo 5

Desarrollo experimental y de ingeniería

Este capítulo expone la arquitectura lógica, el flujo de orquestación y las garantías de reproducibilidad del sistema, de forma que cualquier resultado—figura, tabla o métrica—pueda regenerarse a partir de una configuración cerrada, artefactos versionados y un historial auditable de decisiones [12, 11, 16].

5.1. Arquitectura funcional y flujo

El sistema se organiza como un *pipeline* dirigido por configuración con contratos explícitos entre etapas y artefactos inmutables. La ejecución sigue un recorrido determinista: configuración efectiva → verificación y normalización → representación de hologramas → aprendizaje y calibración → validación y reporte → seguridad de dominio. La *configuración efectiva* se consolida desde un archivo declarativo (`config.yaml`) y fija semillas de NumPy y `scikit-learn`, además de congelar versiones de dependencias para instaurar determinismo a nivel de librerías [20]. La etapa de *verificación y normalización* aplica las operaciones radiométricas y geométricas definidas en el Capítulo 4—percentiles P_1 – P_{99} , tamaño objetivo 512×512 , CLAHE, filtrado de mediana y compensación de tilts/curvaturas en frecuencia—y emite un manifiesto con estadísticas pre/post y huellas criptográficas que anclan el linaje de los datos [6, 4, 8, 19]. La *representación de hologramas* construye

vectores $\mathbf{x}$ a partir de LBP y GLCM, energía en anillos de Fourier y anisotropía espectral, bancos de Gabor, energías wavelet y morfometría; todos los descriptores se estandarizan con estimadores robustos y se someten a reducción univariada confinada al entrenamiento interno para evitar fuga de información [12, 11].

El bloque de *aprendizaje y calibración* ajusta clasificadores complementarios (regresión logística penalizada, SVM RBF, bosque aleatorio y potenciación de gradiente) y combina sus probabilidades en una mezcla convexa cuyos pesos se aprenden para minimizar la pérdida de Brier; la calibración posterior (isotónica o logística) se realiza en un pliegue independiente del usado para la búsqueda de hiperparámetros, preservando la independencia entre etapas [20, 21]. La *validación y reporte* estima ROC-AUC, PR-AUC cuando procede, precisión balanceada, sensibilidad y especificidad con intervalos de confianza por *bootstrap* estratificado, y genera curvas ROC/PR y diagramas de confiabilidad bajo un esquema anidado que confina selección y escalado al entrenamiento [11, 12]. Finalmente, la *seguridad de dominio* entrena un detector de Mahalanobis sobre el subespacio activo, fija umbrales frente a χ_d^2 y calcula contribuciones por característica para explicar alertas; su evaluación usa hologramas externos no sanguíneos, cuantificando tasas de verdadera y falsa alarma y validando la estabilidad de umbrales por remuestreo [14, 15].

5.2. Automatización, trazabilidad y aseguramiento de calidad

La orquestación se expone mediante una interfaz de línea de comandos (`cli.py`) con semántica centrada en tareas. El subcomando **analyze** ejecuta el flujo de punta a punta con la *configuración efectiva* (rutas, parámetros de normalización, radios/orientaciones de descriptores, k de selección, hiperparámetros y semillas); **validate** procesa directorios externos para evaluación y anomalías; **info** y **config** entregan diagnósticos (versiones, semillas, tamaños y rutas efectivas) útiles para auditoría rápida. Cada corrida produce un paquete de resultados con marca temporal que incluye: volcado íntegro de la configuración utilizada, artefactos serializados (vectorizadores, modelos, calibradores y detector) etiquetados con hashes de contenido, bitácoras de ejecución (tiempos, recursos y semillas) y productos analíticos (figuras y tablas). Las etapas intensivas—unificación, extracción y selección—son idempotentes: si la huella

`hash(datos + config)` coincide, se reutiliza el artefacto; si difiere, se regenera y se registra la nueva huella. Este diseño reduce cómputo redundante y hace explícito cuándo y por qué cambian los resultados.

El aseguramiento de calidad combina pruebas de humo que recorren la cadena completa sobre un subconjunto mínimo con verificaciones de contratos (selección confinada al pliegue, fijación de semillas antes de cualquier partición, consistencia de tamaños tras recorte y normalización). El control de versiones registra cambios atómicos y fija `requirements.txt` para preservar determinismo entre instalaciones [20, 16]. En conjunto, la arquitectura—dirigida por configuración, con estados idempotentes, separación estricta entre entrenamiento, búsqueda, calibración y prueba, y evidencia versionada—materializa las garantías de reproducibilidad, trazabilidad y gobernanza requeridas en investigación aplicada en salud, sin depender de detalles contingentes de la disposición física de carpetas [12, 11, 16].

Capítulo 6

Resultados y análisis

Este capítulo presenta la evidencia empírica del sistema propuesto a partir del modelo final entrenado con 84 descriptores y selección automática de 20 variables mediante `SelectKBest`. Se reportan métricas de discriminación, calibración y robustez, así como el desempeño del detector de anomalías. Todas las estimaciones se obtienen bajo el régimen de validación anidada descrito en el Capítulo 4, con control explícito de semillas y artefactos versionados para asegurar reproducibilidad [12, 11, 20].

6.1. Desempeño del modelo y separabilidad de las características

El ensamble final—combinación convexa de regresión logística penalizada, SVM con núcleo RBF, bosque aleatorio y potenciación de gradiente—alcanza una exactitud en prueba de 0,951 y un ROC-AUC de 0,989. La Tabla 6.1 resume las métricas globales, incluyendo la media y desviación estándar de exactitud en validación cruzada estratificada de 5 pliegues.

Tabla 6.1: Métricas del modelo final en el conjunto de prueba y en validación cruzada.

Modelo	Exactitud test	AUC ROC	CV Accuracy (media $\pm$ DE)
Ensamble final	0,951	0,989	0,934 $\pm$ 0,020




Figura 6.1: Distribuciones empíricas de las características más discriminativas. Cada panel compara clases sanas (azul) y falciformes (naranja) en pares de atributos; las líneas punteadas marcan medias por clase.

La Figura 6.1 evidencia que varias combinaciones de atributos producen fronteras casi lineales entre cohortes, coherentes con el buen desempeño de la regresión logística dentro del ensamble. En particular, los perfiles derivados de coocurrencias (p. ej., correlación GLCM), la energía en anillos de Fourier y la energía de detalles wavelet separan con baja solapación las distribuciones de ambas clases, lo que reduce la varianza del estimador y refuerza la estabilidad del sistema ante pequeñas perturbaciones [18, 4, 10]. Este comportamiento avala el diseño del vector de características: descriptores texturales y frecuencias con base física (formación de franjas y contenido espectral) que, al combinarse, capturan anisotropías y granularidad propias de los hologramas de eritrocitos [8].

6.2. Matriz de confusión y curva ROC




Figura 6.2: Matriz de confusión normalizada para el conjunto de prueba.

La matriz de confusión de la Figura 6.2 muestra un equilibrio clínicamente favorable: sensibilidad del 1,00 para la clase falciforme (tasa de verdaderos positivos) y especificidad del 0,90 para la clase sana, consistente con una política de umbral que prioriza la detección de casos patológicos. Esta asimetría controlada responde al criterio costo-sensible adoptado en el capítulo metodológico, en el que se busca minimizar falsos negativos dada su mayor implicación clínica [12, 11]. La estabilidad de estas tasas se corrobora en la validación cruzada, con dispersión acotada de la precisión balanceada.




Figura 6.3: Curva ROC del modelo final con el área bajo la curva correspondiente.

La curva ROC de la Figura 6.3 confirma una discriminación alta a lo largo de todo el rango de umbrales, con $AUC = 0,989$. La proximidad al vértice superior izquierdo indica que, para umbrales intermedios, la sensibilidad y la especificidad superan simultáneamente el 95 %. Este resultado es coherente con la geometría observada en las distribuciones de la Figura 6.1, donde el solapamiento interclase es reducido, y con la combinación de modelos del ensemble, que amortigua sesgos particulares de cada base [20, 21].

6.3. Detección de anomalías y estructura del espacio de características

Tabla 6.2: Resultados de la detección de anomalías en el repositorio externo.

Categoría externa	Imágenes analizadas	Distancia media	Tasa de anomalías
8_ <i>Poaceae</i>	10	85,3	100 %
2_ <i>Aspergillus</i>	10	142,1	100 %
3_ <i>Diatom</i>	10	105,2	100 %

La Tabla 6.2 resume el desempeño del detector de Mahalanobis, ajustado sobre el mismo subespacio de características del clasificador y con umbral operativo fijado en el percentil 95 de las distancias del entrenamiento (9,89). Las categorías externas—organismos ajenos a la hematología—presentan distancias medias dos órdenes de magnitud por encima del umbral, con una tasa de detección del 100 %. Este margen amplio respalda la utilidad del detector como salvaguarda: ante entradas fuera de dominio, la alerta es inequívoca, lo que favorece la abstención informada y la derivación a revisión humana [14, 15, 13].




Figura 6.4: Proyección t-SNE del espacio de características, coloreada por distancia de Mahalanobis.

La proyección de la Figura 6.4 ilustra la estructura geométrica del espacio de características: los clústeres correspondientes a sanos y falciformes forman dos conglomerados dominantes con gradientes de distancia de Mahalanobis crecientes hacia regiones periféricas. La concentración de símbolos con coloraciones intensas fuera de los núcleos de clase indica que el detector es sensible a desviaciones multivariadas coherentes con la covarianza estimada, y que no responde a variaciones marginales aisladas. Esta visualización no participa del entrenamiento, pero corrobora la separación inducida por los descriptores y justifica el umbral adoptado.

6.4. Incertidumbre, calibración y robustez estadística




Figura 6.5: Exactitud con intervalos bootstrap y curva de confiabilidad del modelo final.

La Figura 6.5 sintetiza dos aspectos clave. A la izquierda, el intervalo de confianza al 95 % para la exactitud estimado por *bootstrap* estratificado (2000 remuestreos) muestra una dispersión acotada a pesar del tamaño muestral limitado, en concordancia con las recomendaciones para evaluación en pequeños n [11, 12]. A la derecha, la curva de confiabilidad permanece próxima a la diagonal ideal con una pérdida de Brier de 0,039; esto indica que las probabilidades emitidas por el ensamble son informativas y coherentes con las frecuencias observadas, requisito cuando las salidas se emplean para priorización clínica [20]. La calibración se obtuvo en un pliegue independiente del utilizado para búsqueda de hiperparámetros, preservando la independencia entre etapas y evitando optimismo en la estimación [12].

6.5. Análisis de errores y discusión

El conjunto de prueba registró catorce clasificaciones incorrectas, repartidas entre falsos positivos y negativos. Los falsos negativos se concentran en hologramas de células falciformes con contraste reducido y contenido espectral de altas frecuencias cercano al de eritrocitos sanos; los falsos positivos aparecen en hologramas sanos con patrones de interferencia elongados. En ambos grupos, las contribuciones de características sitúan a la solidez y a la

energía wavelet cerca de los umbrales de decisión, lo que sugiere incrementar, en futuras iteraciones, la representación de estas zonas grises dentro del entrenamiento y explorar ajustes finos de los parámetros de Gabor y de la cuantización GLCM para mejorar sensibilidad local [18, 10].

En conjunto, los resultados corroboran la hipótesis de trabajo: un conjunto de descriptores físicos interpretables, combinado con un ensamble de clasificadores clásicos, alcanza métricas elevadas sin recurrir a reconstrucción del campo complejo. La discriminación ($AUC = 0,989$), la calibración ($Brier = 0,039$) y la detección inequívoca de entradas fuera de dominio sustentan la viabilidad del enfoque para escenarios de cribado, donde la trazabilidad de decisiones y la comunicación de incertidumbre son indispensables [12, 13]. La evidencia sugiere líneas de mejora incremental—enriquecimiento de casos límite y expansión multicéntrica del dataset—compatibles con la arquitectura y el régimen de validación actuales.

Capítulo 7

Conclusiones y trabajo futuro

El estudio confirmó que la clasificación directa de hologramas de eritrocitos sin reconstrucción digital es técnicamente viable cuando se emplea un vector de descriptores con fundamento físico y estadístico, junto con modelos clásicos de aprendizaje automático entrenados y evaluados bajo un régimen anidado de validación y calibración. El ensamble propuesto—mezcla convexa de regresión logística penalizada, SVM con núcleo RBF y modelos basados en árboles—alcanzó una exactitud del 95,1 % y un ROC-AUC de 0,989 en el conjunto de prueba, desempeños consistentes con la geometría observada en el espacio de características y con el control explícito de la complejidad mediante regularización y selección supervisada [20, 21, 12, 11]. La calibración probabilística mostró coherencia entre probabilidades y frecuencias observadas, lo que habilita decisiones costo-sensibles informadas; a su vez, la predicción conforme aporta garantías finito-muestrales de cobertura y un mecanismo de abstención explícita en casos de evidencia ambigua [13]. En paralelo, el detector de anomalías basado en distancia de Mahalanobis demostró capacidad para identificar, con amplio margen, hologramas externos al dominio hematológico, ofreciendo una salvaguarda operativa que complementa la clasificación [14, 15].

El valor agregado del sistema no reside únicamente en sus métricas agregadas, sino en la trazabilidad del proceso y en la transparencia de sus decisiones. La arquitectura dirigida por configuración, la separación estricta entre entrenamiento, búsqueda y calibración, y la emisión de artefactos versionados con huellas criptográficas consolidan un camino reproducible desde los datos

brutos hasta las figuras y tablas reportadas [12, 16]. Esta ingeniería de la reproducibilidad, unida a la interpretabilidad de coeficientes lineales, importancias en árboles y contribuciones en la distancia de Mahalanobis, habilita el diálogo con el especialista y facilita la integración en flujos de laboratorio con recursos moderados. El uso de descriptores texturales, frecuenciales y multiescala, en sintonía con la física de la formación del interferograma, explica por qué es posible prescindir de la reconstrucción del campo complejo sin sacrificar desempeño en este dominio [6, 4, 8].

Limitaciones

Las conclusiones deben leerse a la luz de un tamaño muestral acotado y de la dependencia de un único montaje DLHM, factores que restringen la inferencia fuera del dominio y pueden amplificar la varianza de estimación a pesar del control metodológico adoptado [11, 12]. La ausencia de una caracterización óptica exhaustiva del sistema—distancia muestra–sensor, perfil de iluminación, apodización efectiva—impide vincular cuantitativamente todos los descriptores con parámetros físicos y limita la generación de datos sintéticos controlados [6]. Tampoco se evaluaron fuentes de *dataset shift* severas (cambios de sensor, de protocolo o de población) ni se abordó la clasificación multiclase con otras patologías hematológicas, por lo que la generalización más allá del escenario actual permanece abierta. Finalmente, aunque el detector de Mahalanobis mostró márgenes amplios ante organismos no sanguíneos, su comportamiento frente a cambios sutiles dentro de la hematología requiere validación adicional [15].

Trabajo futuro

Las siguientes líneas se centran exclusivamente en aportes desde la programación y la matemática, manteniendo el mismo marco de gobernanza, validación anidada y trazabilidad.

En primer lugar, resulta pertinente profundizar en *calibración y decisión costo–sensible*. Además de la pérdida de Brier, pueden incorporarse estimadores del *calibration-in-the-large* (intercepto) y la *pendiente de calibración* con intervalos de confianza por *bootstrap*, junto con optimización explícita del umbral τ bajo funciones de utilidad clínica, manteniendo independencia entre

entrenamiento, búsqueda y calibración [20, 12]. La predicción conforme puede extenderse a variantes estratificadas por clase (*Mondrian*) y a protocolos adaptativos que mejoren la eficiencia (tamaño medio de Γ_e) sin deteriorar la cobertura nominal, fortaleciendo el mecanismo de abstención informada [13].

En segundo lugar, se propone un estudio sistemático de *robustez y detección de fuera de dominio*. Sobre la base actual de Mahalanobis, conviene evaluar alternativas robustas adicionales—estimadores MCD con fracciones de soporte variables y pruebas de separación intra/extra-dominio mediante tamaños del efecto y bandas por remuestreo—y comparar con métodos de una sola clase (p. ej., *one-class* con núcleos) bajo el mismo régimen de validación anidada [15, 14, 20]. Un protocolo de *stress testing* estadístico, que perturbe sistemáticamente las distribuciones (barajado de etiquetas controlado, reponderación estratificada), permitiría cuantificar la estabilidad del sistema ante *dataset shift* sin modificar la adquisición [12, 11].

En tercer lugar, es recomendable ampliar el análisis de *parquedad e interpretabilidad* con técnicas de selección estable y penalizaciones esparsas. La combinación de penalizaciones elásticas en la regresión logística, estabilidad de selección por remuestreo y ablaciones por familias de descriptores (LBP, GLCM, Fourier, Gabor, wavelet, morfometría) proporcionaría curvas desempeño-dimensión y justificaría configuraciones mínimas con la misma exactitud/calibración [20, 12]. Complementariamente, pueden incluirse comparaciones emparejadas entre modelos base y el ensamble para documentar formalmente la reducción de varianza aportada por la mezcla convexa [21].

En cuarto lugar, se sugiere desarrollar *infraestructura de evaluación continua* y liberación reproducible: pruebas de regresión sobre subconjuntos canónicos, verificación automática de contratos (selección confinada al pliegue, semillas fijadas antes de particiones, consistencia de tamaños tras normalización), generación de *model cards/data cards* con métricas desagregadas y reporte automatizado de calibración e incertidumbre, todo ello empaquetado en artefactos versionados conforme a las directrices institucionales de trazabilidad [16, 12]. Esta capa MLOps científica no altera el algoritmo, pero incrementa la confiabilidad operativa y la auditabilidad.

Finalmente, en la dimensión *metodológica*, es natural investigar esquemas semisupervisados y con débil supervisión (autoetiquetado con umbrales conservadores respaldados por predicción conforme) para aprovechar grandes volúmenes de hologramas sin rótulo; el rendimiento de estas variantes de-

be medirse con las mismas salvaguardas de calibración e incertidumbre, y compararse con la línea base mediante pruebas emparejadas y bandas de *bootstrap* [13, 12, 11]. Estas extensiones—estrictamente algorítmicas y estadísticamente controladas—mantienen la filosofía del proyecto: parsimonia, interpretabilidad y garantías cuantitativas de desempeño.

Bibliografía

- [1] W. A. Arishi, H. A. Alhadrami, and M. Zourob, “Techniques for the detection of sickle cell disease: A review,” *Micromachines*, vol. 12, no. 5, p. 453, 2021.
- [2] P. T. McGann and C. Hoppe, “The pressing need for point-of-care diagnostics for sickle cell disease: A review of current and future technologies,” *Blood Cells, Molecules, and Diseases*, vol. 67, pp. 104–113, 2017.
- [3] P. Shrestha *et al.*, “Evaluation of low-cost techniques to detect sickle cell disease and β -thalassemia: an open-label, international, multicentre study,” *The Lancet Regional Health – Southeast Asia*, vol. 15, p. 100356, 2025.
- [4] S. Amann, M. von Witzleben, and S. Breuer, “3d-printable portable open-source platform for low-cost lens-less holographic cellular imaging,” *Scientific Reports*, vol. 9, pp. 1–9, 2019.
- [5] C. Buitrago-Duque, B. P. no Jurado, and J. Garcia-Sucerquia, “Robust and compact digital lensless holographic microscope for label-free blood smear analysis,” *HardwareX*, vol. 14, p. e00428, 2023.
- [6] A. Greenbaum, W. Luo, and A. Ozcan, “Wide-field computational imaging of pathology slides using lens-free on-chip microscopy,” *Science Translational Medicine*, vol. 6, no. 267, p. 267ra175, 2014.
- [7] J. Kim *et al.*, “Single-shot three-dimensional morphology of biological cells in digital holographic microscopy using a physics-driven neural network,” *Nature Communications*, vol. 16, p. 1123, 2025.
- [8] T. O’Connor *et al.*, “Deep learning-based cell identification and disease diagnosis using spatio-temporal cellular dynamics in compact digital

- holographic microscopy,” *Biomedical Optics Express*, vol. 11, no. 2, pp. 1225–1242, 2020.
- [9] H. Sazak and M. Kotan, “Automated blood cell detection and classification in microscopic images using yolov11,” *Diagnostics*, vol. 14, no. 1, p. 52, 2024.
- [10] L. Alzubaidi *et al.*, “Deep learning models for classification of red blood cells in microscopy images to aid in sickle cell anemia diagnosis,” *Electronics*, vol. 9, no. 3, p. 427, 2020.
- [11] A. Vabalas, E. Gowen, E. Poliakoff, and A. J. Casson, “Machine learning algorithm validation with a limited sample size,” *PLOS ONE*, vol. 14, no. 11, p. e0224365, 2019.
- [12] I. Tsamardinos *et al.*, “Don’t lose samples to estimation,” *Patterns*, vol. 3, no. 7, p. 100568, 2022.
- [13] J. Montero *et al.*, “Explainable machine learning in medical imaging: From theory to clinical practice,” *IEEE Access*, vol. 12, pp. 123 456–123 478, 2024.
- [14] P. C. Mahalanobis, “On the generalised distance in statistics,” *Proceedings of the National Institute of Sciences of India*, vol. 2, no. 1, pp. 49–55, 1936.
- [15] P. J. Rousseeuw *et al.*, “Anomaly detection by robust statistics,” *Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery*, vol. 9, no. 2, p. e1233, 2019.
- [16] U. EAFIT, “Reglamento de propiedad intelectual,” 2018, accedido: sep. 16, 2025. [Online]. Available: <https://www.eafit.edu.co/institucional/reglamentos/Documents/reglamento-propiedad-intelectual-enero-2018-1.pdf>
- [17] G. Dheepak *et al.*, “Brain tumor classification: a novel approach integrating glcm, lbp and composite features,” *Frontiers in Oncology*, vol. 13, p. 117234, 2023.
- [18] S. Barburiceanu, R. Terebes, and S. Meza, “3d texture feature extraction and classification using glcm and lbp-based descriptors,” *Applied Sciences*, vol. 11, no. 4, p. 1679, 2021.

- [19] B. B. Singh *et al.*, “Efficient medical image enhancement using clahe,” *International Journal of Computer Applications*, vol. 162, no. 6, pp. 11–15, 2017.
- [20] F. Pedregosa *et al.*, “Scikit-learn: Machine learning in Python,” *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.
- [21] J. H. Friedman, “Greedy function approximation: A gradient boosting machine,” *Annals of Statistics*, vol. 29, no. 5, pp. 1189–1232, 2001.